

第六讲 最小二乘法及其应用

贺丽君

信息与通信工程学院

Email: lijunhe@mail.xjtu.edu.cn

2023-02


内容提要

- 最小二乘法
 - 应用举例1: Netflix电影推荐
 - 应用举例2: 信道估计
-

内容提要

- 最小二乘法
 - 应用举例1: Netflix电影推荐
 - 应用举例2: 信道估计
-

最小二乘法的提出——直线拟合



$$C + D \cdot 0 = 6$$

$$C + D \cdot 1 = 0 \quad \Rightarrow \quad \mathbf{Ax} = \mathbf{b}$$

$$C + D \cdot 2 = 0$$

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix} \quad \mathbf{x} = \begin{bmatrix} C \\ D \end{bmatrix} \quad \mathbf{b} = \begin{bmatrix} 6 \\ 0 \\ 0 \end{bmatrix}$$

方程组 $\mathbf{Ax} = \mathbf{b}$ 无解！

$$\|Ax - b\|^2$$



$$m \times n \quad n \times 1 \quad m \times 1$$

最小二乘法的提出——直线拟合

$$\text{minimize } \|\mathbf{Ax} - \mathbf{b}\|^2$$

向量 \mathbf{b} 可以分解为两部分之和：


$$\mathbf{b} = \mathbf{p} + \mathbf{e}$$

列空间分量


左零空间分量

$$\|\mathbf{Ax} - \mathbf{b}\|^2 = \|\mathbf{Ax} - \mathbf{p} - \mathbf{e}\|^2 = \|\mathbf{Ax} - \mathbf{p}\|^2 + \|\mathbf{e}\|^2$$

该项等于零，则目标函数最小



子空间投影



假设各列
线性无关

$$\mathbf{A} = [\mathbf{a}_1 \cdots \mathbf{a}_n]$$

$$\begin{bmatrix} -\mathbf{a}_1^T \\ \vdots \\ -\mathbf{a}_n^T \end{bmatrix} \begin{bmatrix} \mathbf{b} - \mathbf{A}\hat{\mathbf{x}} \end{bmatrix} = \begin{bmatrix} 0 \end{bmatrix} \Rightarrow$$

\mathbf{A}^T

$$\hat{\mathbf{x}} = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{b}$$

$$\mathbf{p} = \mathbf{A}\hat{\mathbf{x}} = \mathbf{A}(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{b}$$

$$\mathbf{P} = \mathbf{A}(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T$$

$$\mathbf{P}^2 = \mathbf{P}, \mathbf{P}^T = \mathbf{P}$$

子空间投影

最小二乘法的提出——直线拟合

$$\text{minimize } \|\mathbf{Ax} - \mathbf{b}\|^2$$

向量 \mathbf{b} 可以分解为两部分之和：

$$\mathbf{b} = \mathbf{p} + \mathbf{e}$$


列空间分量

左零空间分量


$$\|\mathbf{Ax} - \mathbf{b}\|^2 = \|\mathbf{Ax} - \mathbf{p} - \mathbf{e}\|^2 = \|\mathbf{Ax} - \mathbf{p}\|^2 + \|\mathbf{e}\|^2$$

该项等于零，则目标函数最小

$$\Rightarrow \hat{\mathbf{x}} = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{b} \quad (\text{最小二乘解, Least Squares})$$



最小二乘法的提出——直线拟合



$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix} \quad \mathbf{b} = \begin{bmatrix} 6 \\ 0 \\ 0 \end{bmatrix} \quad \hat{\mathbf{x}} = \begin{bmatrix} 5 \\ -3 \end{bmatrix}$$

$$\|\mathbf{e}\|^2 = e_1^2 + e_2^2 + e_3^2 = 6$$

$$e_1 + e_2 + e_3 = 0$$

为什么?

直线拟合的一般情况

$$\begin{aligned} C + Dt_1 &= b_1 \\ C + Dt_2 &= b_2 \\ &\vdots \\ C + Dt_m &= b_m \end{aligned} \quad A = \begin{bmatrix} 1 & t_1 \\ 1 & t_2 \\ \vdots & \vdots \\ 1 & t_m \end{bmatrix}$$

$$A^T A = \begin{bmatrix} 1 & \cdots & 1 \\ t_1 & \cdots & t_m \end{bmatrix} \begin{bmatrix} 1 & t_1 \\ \vdots & \vdots \\ 1 & t_m \end{bmatrix} = \begin{bmatrix} m & \sum t_i \\ \sum t_i & \sum t_i^2 \end{bmatrix}$$

$$A^T \mathbf{b} = \begin{bmatrix} 1 & \cdots & 1 \\ t_1 & \cdots & t_m \end{bmatrix} \begin{bmatrix} b_1 \\ \vdots \\ b_m \end{bmatrix} = \begin{bmatrix} \sum b_i \\ \sum t_i b_i \end{bmatrix}$$

直线拟合的一般情况

LS本质是参数拟合，不限于直线

标准方程 (Normal Equation):

$$\begin{bmatrix} m & \sum t_i \\ \sum t_i & \sum t_i^2 \end{bmatrix} \begin{bmatrix} C \\ D \end{bmatrix} = \begin{bmatrix} \sum b_i \\ \sum t_i b_i \end{bmatrix}$$

$\mathbf{A}^T \mathbf{A} \quad \hat{\mathbf{x}} \quad \mathbf{A}^T \mathbf{b}$

$$E(\mathbf{x}) = \|\mathbf{Ax} - \mathbf{b}\|^2 = (C + Dt_1 - b_1)^2 + \dots + (C + Dt_m - b_m)^2$$

$$\frac{\partial E}{\partial C} = 0 \Rightarrow$$

$$mC + D \sum t_i = \sum b_i$$

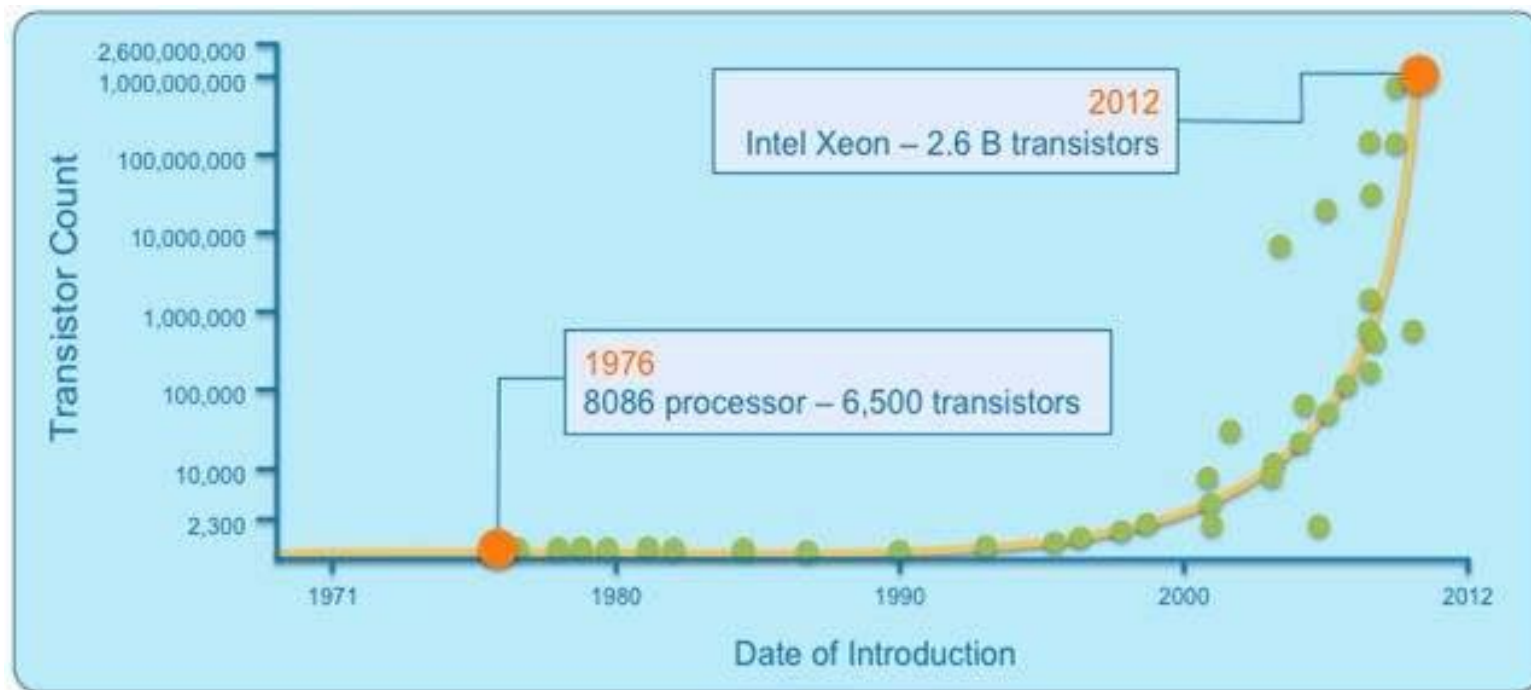
$$\frac{\partial E}{\partial D} = 0 \Rightarrow$$

$$C \sum t_i + D \sum t_i^2 = \sum t_i b_i$$

与标准方程一致

曲线拟合：摩尔定律

intel价格不变的情况下，处理器包含的晶体管的数量变化规律

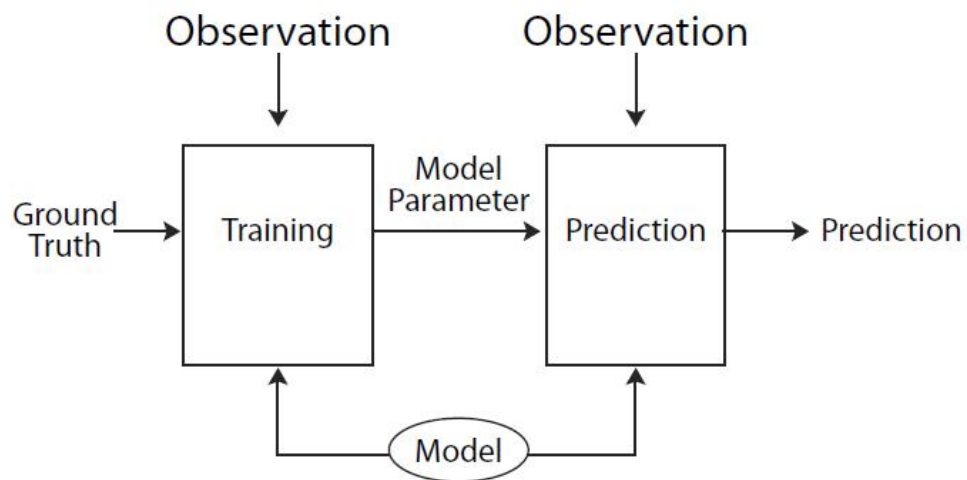



戈登·摩尔的经验之谈：集成电路上可以容纳的晶体管数目在大约每经过**18**个月到**24**个月便会增加一倍。处理器的性能大约每两年翻一倍，同时价格下降为之前的一半。

内容提要

- 最小二乘法
 - 应用举例1: Netflix电影推荐
 - 应用举例2: 信道估计
-

Netflix电影个性化推荐



电影推荐问题：
预测器设计

Netflix电影个性化推荐

体现用户偏好
和影片质量

R =

	A	B	C	D	E
1	5	4	4	—	5
2	—	3	5	3	4
3	5	2	—	2	3
4	—	2	3	1	2
5	4	—	5	4	5
6	5	3	—	3	5
7	3	2	3	2	—
8	5	3	4	—	5
9	4	2	5	4	—
10	5	—	5	3	4

$$\hat{r}_{ui} = \bar{r} + b_u + b_i$$

平均值=3.83

优化目标：

$$\text{minimize}_{\{b_u, b_i\}} \sum_{(u,i)} (r_{ui} - \hat{r}_{ui})^2$$

遍历训练集

- 利用训练集获得模型参数
- 利用测试集验证性能

$$\text{RMSE} = \sqrt{\sum_{(u,i)} \frac{(r_{ui} - \hat{r}_{ui})^2}{C}}$$

Netflix 电影个性化推荐

$$\|Ab - c\|_2^2$$

$$\text{minimize}_{\{b_u, b_i\}} \sum_{(u,i)} (r_{ui} - \hat{r}_{ui})^2$$

$$\hat{r}_{ui} = \bar{r} + b_u + b_i$$

30个方程，对应训练集中样本数

$$\begin{pmatrix} 1 \\ 2 \\ \vdots \\ 30 \end{pmatrix} \begin{pmatrix} 1 & 2 & 3 & \dots & 10 & A & B & \dots & E \\ 1 & 0 & 0 & \dots & 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 & 1 & 0 & \dots & 0 \\ \vdots & \vdots & & & \ddots & & & \vdots & \\ 0 & 0 & 0 & \dots & 1 & 0 & 0 & \dots & 1 \end{pmatrix}$$

$$(A^T A) b = A^T c$$

(最小二乘解)

$$\begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_{10} \\ b_A \\ b_B \\ \vdots \\ b_E \end{pmatrix}$$

$$\begin{pmatrix} r_{1A} - \bar{r} \\ r_{3A} - \bar{r} \\ \vdots \\ r_{10E} - \bar{r} \end{pmatrix}$$

15个待估参数

Netflix电影个性化推荐

$$\mathbf{b}_u^* = [0.62, 0.42, -0.28, -1.78, 0.52, 0.49, -1.24, 0.45, 0.40, 0.23]^T$$

$$\mathbf{b}_i^* = [0.72, -1.20, 0.60, -0.60, 0.33]^T$$

	A	B	C	D	E
1	5.00	3.09	4.90	—	4.62
2	—	2.89	4.69	3.49	4.42
3	4.10	2.19	—	2.78	3.71
4	—	1.00	2.49	1.29	2.22
5	4.90	—	4.79	3.58	4.51
6	4.88	2.96	—	3.56	4.48
7	3.15	1.23	3.03	1.82	—
8	4.84	2.92	4.72	—	4.44
9	4.84	2.92	4.72	3.51	—
10	4.61	—	4.49	3.29	4.22


RMSE=

0.51 (训练集)


0.58 (测试集)

Netflix电影个性化推荐——实现问题

➤ 考虑相关性的加权预测



1. 用户间的相关性：用户品味
2. 电影的质量



➤ 时变因素


$$b_i(t) = b_i + b_{i,\text{bin}(t)} \quad b_u(t) = b_u + \sigma_u(t) + b_{u,t}$$

$$\hat{r}_{ui}(t) = \bar{r} + b_i(t) + b_u(t)$$

内容提要

- 最小二乘法
 - 应用举例1: Netflix电影推荐
 - 应用举例2: 信道估计
-

无线通信中的信道估计



- 信道估计是接收机实现相干检测的基础
- 信道估计是无线通信系统的关键技术之一

基于导频的LS信道估计

K 副天线



eNodeB

$$\mathbf{h} = \begin{bmatrix} h_1 \\ \vdots \\ h_K \end{bmatrix}$$

UE

1 副天线

导频

数据

导频

数据

$$\begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1K} \\ x_{21} & x_{22} & \cdots & x_{2K} \\ \vdots & \vdots & \ddots & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{NK} \end{bmatrix} \begin{bmatrix} h_1 \\ \vdots \\ h_K \end{bmatrix} + \begin{bmatrix} n_1 \\ \vdots \\ n_N \end{bmatrix}$$

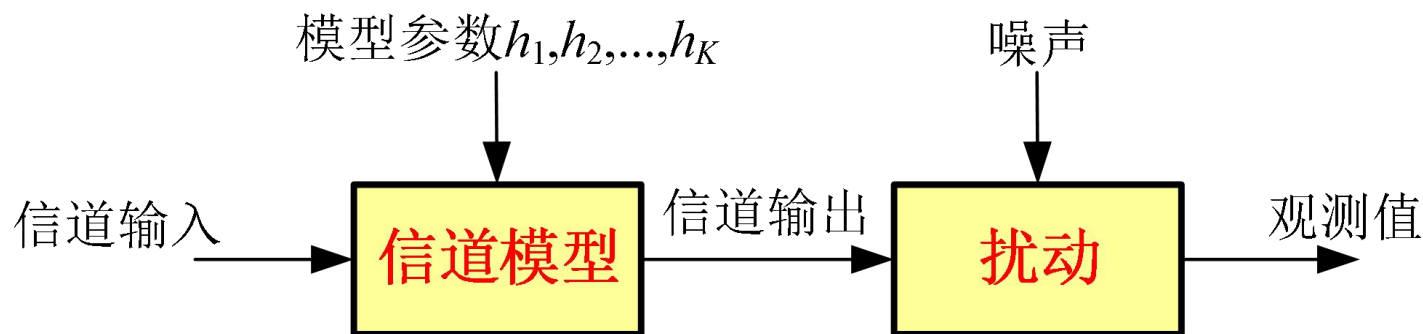
时刻 t

天线1的导频序列

用于估计 h_1 的导频序列

信道估计本质上是
系统辨识问题

基于导频的LS信道估计



$$\begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1K} \\ x_{21} & x_{22} & \cdots & x_{2K} \\ \vdots & \vdots & & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{NK} \end{bmatrix} \begin{bmatrix} h_1 \\ \vdots \\ h_K \end{bmatrix} + \begin{bmatrix} n_1 \\ \vdots \\ n_N \end{bmatrix}$$

寻找能够对观测值给出最佳解释的模型参数

$$\text{minimize } \|\mathbf{y} - \mathbf{X}\mathbf{h}\|^2 \Rightarrow \hat{\mathbf{h}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

基于导频的LS信道估计

$$\begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix} = \underbrace{\begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1K} \\ x_{21} & x_{22} & \cdots & x_{2K} \\ \vdots & \vdots & & \vdots \\ x_{N1} & x_{N2} & \cdots & x_{NK} \end{bmatrix}}_{\mathbf{X}} \begin{bmatrix} h_1 \\ \vdots \\ h_K \end{bmatrix} + \begin{bmatrix} n_1 \\ \vdots \\ n_N \end{bmatrix}$$

1. 保证可逆?
2. 什么样的导频序列是最好?

$$\text{minimize } \|\mathbf{y} - \mathbf{X}\mathbf{h}\|^2 \Rightarrow \hat{\mathbf{h}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

$$(\mathbf{X}^T \mathbf{X}) = \begin{bmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_K^T \end{bmatrix} [\mathbf{x}_1 \cdots \mathbf{x}_K] = \begin{bmatrix} \|\mathbf{x}_1\|^2 & 0 & \cdots & 0 \\ \vdots & \ddots & & \vdots \\ 0 & 0 & \cdots & \|\mathbf{x}_K\|^2 \end{bmatrix} \xrightarrow{\text{能量限制为1}} \hat{\mathbf{h}} = \mathbf{X}^T \mathbf{y} = \begin{bmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_K^T \end{bmatrix} \mathbf{y} = \begin{bmatrix} \mathbf{x}_1^T \mathbf{y} \\ \vdots \\ \mathbf{x}_K^T \mathbf{y} \end{bmatrix}$$

导频正交时各个信道估计可以独立进行

谢谢大家！
