

第十讲 奇异值分解

贺丽君

信息与通信工程学院

Email: lijunhe@mail.xjtu.edu.cn

2023-04

内容提要

- 奇异值分解的引入
 - 奇异值分解及其几何意义
 - 奇异值分解与图像数据压缩
 - 奇异值分解在多天线系统中的应用
-

内容提要

- 奇异值分解的引入
 - 奇异值分解及其几何意义
 - 奇异值分解与图像数据压缩
 - 奇异值分解在多天线系统中的应用
-

奇异值分解的引入


对角化是实现
解耦的关键

$$S^{-1}AS = \Lambda = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix}$$

矩阵可对角化的条件：

- 矩阵 A 为方阵
- 矩阵 A 有 n 个线性无关的特征向量

对于任意的 $m \times n$ 矩阵，如何将其“对角化”？



奇异值分解的引入

n 维空间的
标准正交基

假设 A 为 $m \times n$ 矩阵， x 为 n 维向量，则有：

$$Ax = A(\underline{c_1 v_1} + \underline{c_2 v_2} + \dots + \underline{c_n v_n})$$

由于：

$$Av_i = d_{1i} \mathbf{u}_1 + d_{2i} \mathbf{u}_2 + \dots + d_{mi} \mathbf{u}_m$$

m 维空间的标
准正交基


所以有：

$$A \begin{bmatrix} v_1 & v_2 & \cdots & v_n \end{bmatrix} = \begin{bmatrix} u_1 & u_2 & \cdots & u_m \end{bmatrix} \begin{bmatrix} d_{11} & d_{12} & \cdots & d_{1n} \\ \vdots & \vdots & \vdots & \vdots \\ d_{m1} & d_{m2} & \cdots & d_{mn} \end{bmatrix}$$

奇异值分解的引入

$$\mathbf{A} \begin{bmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_n \end{bmatrix} = \begin{bmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_m \end{bmatrix} \begin{bmatrix} d_{11} & d_{12} & \cdots & d_{1n} \\ \vdots & \vdots & \vdots & \vdots \\ d_{m1} & d_{m2} & \cdots & d_{mn} \end{bmatrix}$$


正交矩阵 正交矩阵



$$\begin{bmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_m \end{bmatrix}^T \mathbf{A} \begin{bmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_n \end{bmatrix} = \begin{bmatrix} d_{11} & d_{12} & \cdots & d_{1n} \\ \vdots & \vdots & \vdots & \vdots \\ d_{m1} & d_{m2} & \cdots & d_{mn} \end{bmatrix}$$

“对角阵”?

奇异值分解的引入



奇异值分解的引入

$$\mathbf{A}[\mathbf{v}_1 \ \mathbf{v}_2 \ \cdots \ \mathbf{v}_n] = [\mathbf{u}_1 \ \mathbf{u}_2 \ \cdots \ \mathbf{u}_m] \begin{bmatrix} d_{11} & d_{12} & \cdots & d_{1n} \\ \vdots & \vdots & \vdots & \vdots \\ d_{m1} & d_{m2} & \cdots & d_{mn} \end{bmatrix}$$

根据零空间的定义:

$$\mathbf{A}\mathbf{v}_i = \mathbf{0}, \quad r+1 \leq i \leq n$$

$n-r$ 个全零列

$$\mathbf{A}\mathbf{V} = \mathbf{U}\mathbf{\Sigma}$$

对角阵

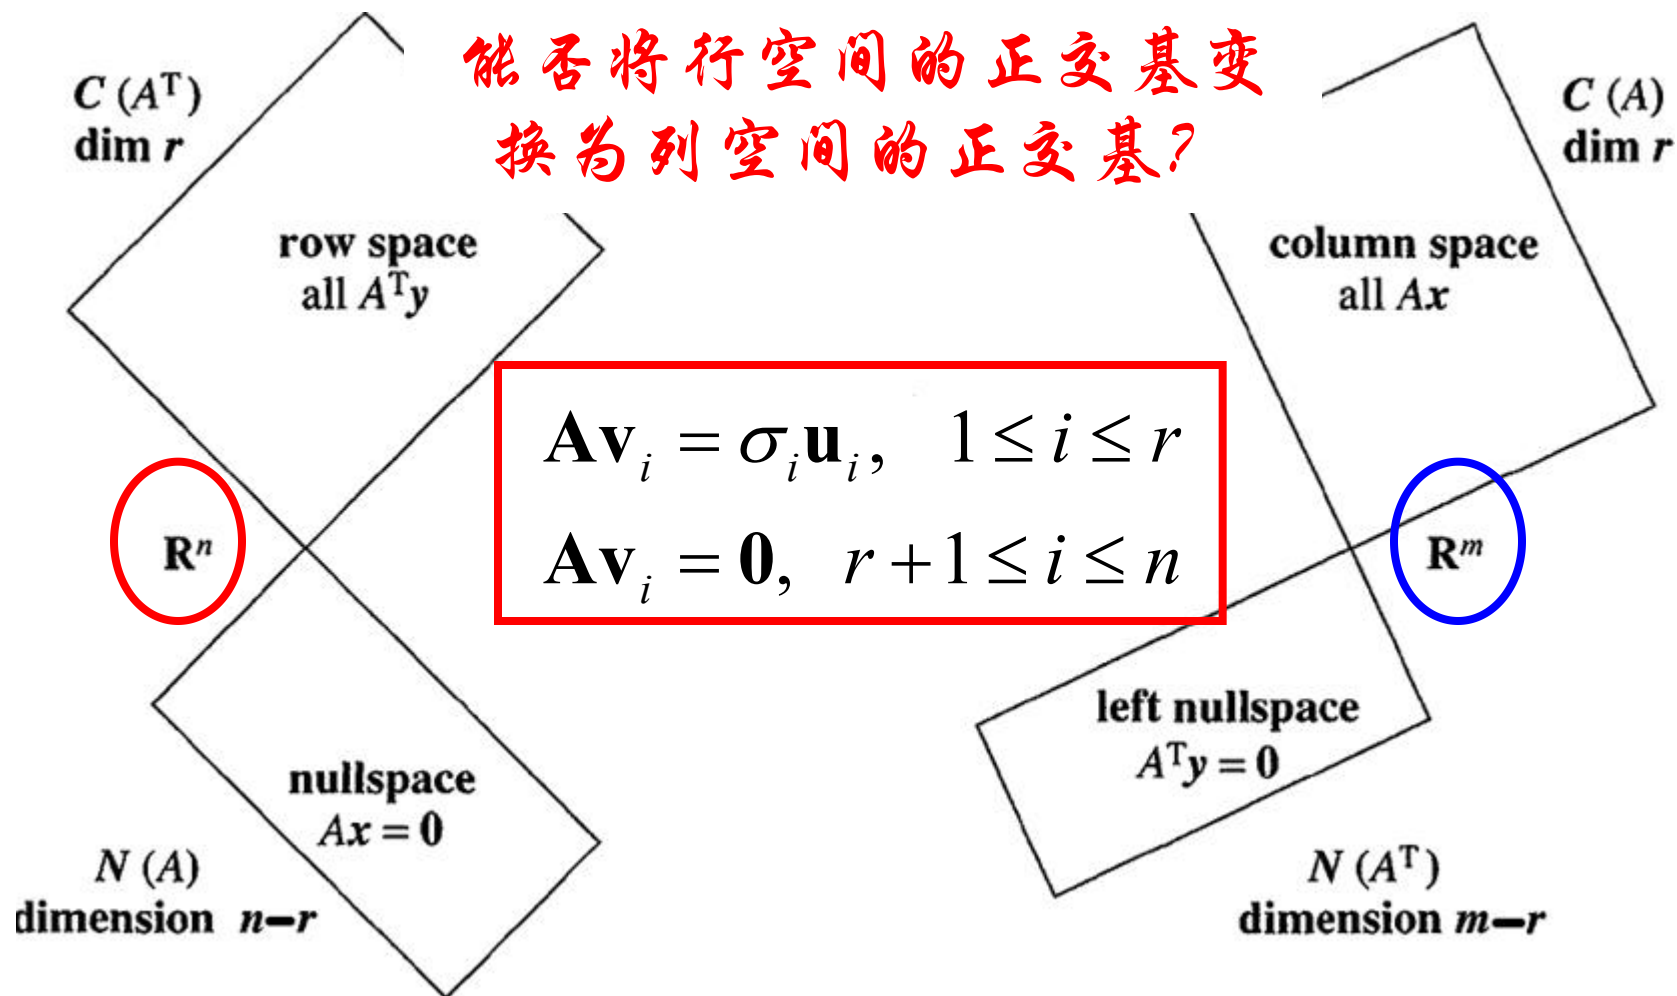
$$\mathbf{A}[\mathbf{v}_1 \ \mathbf{v}_2 \ \cdots \ \mathbf{v}_n] = [\mathbf{u}_1 \ \mathbf{u}_2 \ \cdots \ \mathbf{u}_m]$$

$m-r$ 个全零行

$$\begin{bmatrix} \sigma_1 & & & & \\ & \sigma_2 & & & \\ & & \ddots & & \\ & & & \sigma_r & \\ 0 & & & & 0 \end{bmatrix}$$

奇异值分解的引入

能否将行空间的正交基变换为列空间的正交基?



内容提要

- 奇异值分解的引入
 - 奇异值分解及其几何意义
 - 奇异值分解与图像数据压缩
 - 奇异值分解在多天线系统中的应用
-

奇异值分解

$$\mathbf{A}\mathbf{v}_i = \sigma_i \mathbf{u}_i, \quad 1 \leq i \leq r$$

$$\mathbf{A}\mathbf{v}_i = \mathbf{0}, \quad r+1 \leq i \leq n$$

假设 $\mathbf{w}_1 \sim \mathbf{w}_n$ 是 n 维空间的任意一组标准正交基:

$$\{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_n\} \xrightarrow{\mathbf{A}} \{\mathbf{A}\mathbf{w}_1, \mathbf{A}\mathbf{w}_2, \dots, \mathbf{A}\mathbf{w}_n\}$$

如果要使各 $\mathbf{A}\mathbf{w}_i$ 两两正交, 应有:

$$(\mathbf{A}\mathbf{w}_i)^T \mathbf{A}\mathbf{w}_j = 0, \quad i \neq j$$

实对称
矩阵

即:

$$(\mathbf{w}_i)^T \mathbf{A}^T \mathbf{A} \mathbf{w}_j = 0, \quad i \neq j$$

1. 特征值全是实数 2. n 个标准正交的特征向量

奇异值分解

由于 $\mathbf{A}^T\mathbf{A}$ 是实对称矩阵，因此， $\mathbf{w}_1 \sim \mathbf{w}_n$ 可以选取为 $\mathbf{A}^T\mathbf{A}$ 的标准正交特征向量，此时有：

$$(\mathbf{w}_i)^T \mathbf{A}^T \mathbf{A} \mathbf{w}_j = (\mathbf{w}_i)^T \lambda_j \mathbf{w}_j = 0$$

而 $\mathbf{A}^T\mathbf{A}$ 的特征值具有如下两条性质：

□ $\mathbf{A}^T\mathbf{A}$ 和 $\mathbf{A}\mathbf{A}^T$ 的特征值均为非负实数

$$\mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} = \mathbf{x}^T \lambda \mathbf{x} \Rightarrow (\mathbf{A} \mathbf{x})^T \mathbf{A} \mathbf{x} = \lambda \mathbf{x}^T \mathbf{x} \Rightarrow \|\mathbf{A} \mathbf{x}\|^2 = \lambda \|\mathbf{x}\|^2$$

$$\mathbf{x}^T \mathbf{A} \mathbf{A}^T \mathbf{x} = \mathbf{x}^T \lambda \mathbf{x} \Rightarrow (\mathbf{A}^T \mathbf{x})^T \mathbf{A}^T \mathbf{x} = \lambda \mathbf{x}^T \mathbf{x} \Rightarrow \|\mathbf{A}^T \mathbf{x}\|^2 = \lambda \|\mathbf{x}\|^2$$

奇异值分解

由于 $\mathbf{A}^T\mathbf{A}$ 是实对称矩阵，因此， $\mathbf{w}_1 \sim \mathbf{w}_n$ 可以选取为 $\mathbf{A}^T\mathbf{A}$ 的标准正交特征向量，此时有：

$$(\mathbf{w}_i)^T \mathbf{A}^T \mathbf{A} \mathbf{w}_j = (\mathbf{w}_i)^T \lambda_j \mathbf{w}_j = 0$$

而 $\mathbf{A}^T\mathbf{A}$ 的特征值具有如下两条性质：

□ $\mathbf{A}^T\mathbf{A}$ 和 $\mathbf{A}\mathbf{A}^T$ 的特征值均为非负实数

□ $\mathbf{A}^T\mathbf{A}$ 和 $\mathbf{A}\mathbf{A}^T$ 均有 r 个非零特征值，且非零特征值相同

$$\text{rank}(\mathbf{A}) = \text{rank}(\mathbf{A}^T \mathbf{A}) \xRightarrow{\text{转置不改变矩阵的秩}} \text{rank}(\mathbf{A}^T) = \text{rank}(\mathbf{A}\mathbf{A}^T)$$

$\mathbf{A}^T\mathbf{A}$ 实对称矩阵有 n 个线性无关的特征向量，则对角化特征值个数相同

$$\mathbf{A}^T \mathbf{A} \mathbf{x} = \lambda \mathbf{x} \Rightarrow \mathbf{A} \mathbf{A}^T \mathbf{A} \mathbf{x} = \mathbf{A} \lambda \mathbf{x}$$

$$(\mathbf{A}\mathbf{A}^T) \mathbf{A} \mathbf{x} = \lambda \mathbf{A} \mathbf{x} \xRightarrow{\mathbf{A} \mathbf{x} \neq \mathbf{0}} \lambda \text{ 是 } \mathbf{A}\mathbf{A}^T \text{ 的特征值}$$

奇异值分解

由于 $\mathbf{A}^T\mathbf{A}$ 是实对称矩阵，因此， $\mathbf{w}_1 \sim \mathbf{w}_n$ 可以选取为 $\mathbf{A}^T\mathbf{A}$ 的标准正交特征向量，此时有：

$$(\mathbf{w}_i)^T \mathbf{A}^T \mathbf{A} \mathbf{w}_j = (\mathbf{w}_i)^T \lambda_j \mathbf{w}_j = 0$$

而 $\mathbf{A}^T\mathbf{A}$ 的特征值具有如下两条性质：

□ $\mathbf{A}^T\mathbf{A}$ 和 $\mathbf{A}\mathbf{A}^T$ 的特征值均为非负实数

□ $\mathbf{A}^T\mathbf{A}$ 和 $\mathbf{A}\mathbf{A}^T$ 均有 r 个非零特征值，且非零特征值相同
所以有：

$$\mathbf{A}^T \mathbf{A} \mathbf{w}_i = \lambda_i \mathbf{w}_i, \quad 1 \leq i \leq r \quad (\lambda_i > 0)$$

$$\mathbf{A}^T \mathbf{A} \mathbf{w}_i = \mathbf{0}, \quad r+1 \leq i \leq n$$

$\mathbf{A}^T\mathbf{A}$ 实对称矩阵有 n 个特征值，其中 r 个非零， $n-r$ 个零

奇异值分解

$$(\mathbf{A}\mathbf{w}_i)^T \mathbf{A}\mathbf{w}_j = 0, \quad i \neq j$$

*orthogonal
basis for $C(\mathbf{A})$*

$$\mathbf{A}^T \mathbf{A}\mathbf{w}_i = \lambda_i \mathbf{w}_i, \quad 1 \leq i \leq r$$

$$\mathbf{A}^T \mathbf{A}\mathbf{w}_i = \mathbf{0}, \quad r+1 \leq i \leq n$$

零向量

注意到:

$$\|\mathbf{A}\mathbf{w}_i\|^2 = (\mathbf{A}\mathbf{w}_i)^T \mathbf{A}\mathbf{w}_i = \mathbf{w}_i^T \mathbf{A}^T \mathbf{A}\mathbf{w}_i = \mathbf{w}_i^T (\lambda_i \mathbf{w}_i) = \lambda_i$$

将列空间的正交基归一化可得标准正交基:

$$\mathbf{u}_i = \frac{\mathbf{A}\mathbf{w}_i}{\sqrt{\lambda_i}}, \quad 1 \leq i \leq r$$

奇异值分解

$$\mathbf{u}_i = \frac{\mathbf{A}\mathbf{w}_i}{\sqrt{\lambda_i}}, \quad 1 \leq i \leq r \quad \longleftrightarrow \quad \mathbf{A}\mathbf{w}_i = \sqrt{\lambda_i} \mathbf{u}_i, \quad 1 \leq i \leq r$$

又因为:

$$\mathbf{A}^T \mathbf{A} \mathbf{w}_i = \lambda_i \mathbf{w}_i, \quad 1 \leq i \leq r$$

所以:

$$\mathbf{A}^T \sqrt{\lambda_i} \mathbf{u}_i = \lambda_i \mathbf{w}_i, \quad 1 \leq i \leq r$$

$$\mathbf{A}^T \mathbf{u}_i = \sqrt{\lambda_i} \mathbf{w}_i, \quad 1 \leq i \leq r$$

行向量的线性组合

$\mathbf{w}_1, \dots, \mathbf{w}_r$ 是 $C(\mathbf{A}^T)$ 的标准正交基

$$\mathbf{w}_i \in C(\mathbf{A}^T)$$

奇异值分解

另一方面：

$$\mathbf{A}^T \mathbf{A} \mathbf{w}_i = \mathbf{0}, \quad r+1 \leq i \leq n$$

$$\mathbf{w}_i^T \mathbf{A}^T \mathbf{A} \mathbf{w}_i = \|\mathbf{A} \mathbf{w}_i\|^2 = 0, \quad r+1 \leq i \leq n$$


$$\mathbf{W} = \mathbf{V}$$



$$\mathbf{A} \mathbf{w}_i = \mathbf{0}, \quad r+1 \leq i \leq n$$

$\mathbf{w}_{r+1}, \dots, \mathbf{w}_n$ 是 $N(\mathbf{A})$ 的标准正交基

$$\mathbf{A} \mathbf{w}_i = \sqrt{\lambda_i} \mathbf{u}_i, \quad 1 \leq i \leq r$$

$$\mathbf{A} \mathbf{w}_i = \mathbf{0}, \quad r+1 \leq i \leq n$$



$$\mathbf{A} \mathbf{v}_i = \sigma_i \mathbf{u}_i, \quad 1 \leq i \leq r$$

$$\mathbf{A} \mathbf{v}_i = \mathbf{0}, \quad r+1 \leq i \leq n$$

奇异值分解 (SVD)


$$\mathbf{A}\mathbf{v}_i = \sigma_i \mathbf{u}_i, \quad 1 \leq i \leq r$$

$$\mathbf{A}\mathbf{v}_i = \mathbf{0}, \quad r+1 \leq i \leq n$$

右奇异向量 左奇异向量

$$\mathbf{A} \left[\underline{\mathbf{v}_1 \cdots \mathbf{v}_r} \cdots \mathbf{v}_n \right] = \left[\underline{\mathbf{u}_1 \cdots \mathbf{u}_r} \cdots \mathbf{u}_m \right] \begin{bmatrix} \sigma_1 & & & & \\ & \ddots & & & \\ & & \sigma_r & & \\ & & & \mathbf{0} & \\ \mathbf{0} & & & & \mathbf{0} \end{bmatrix}$$

r 个奇异值



$$\mathbf{A}_{m \times n} = \mathbf{U}_{m \times m} \mathbf{\Sigma}_{m \times n} \mathbf{V}_{n \times n}^T$$

奇异值分解 (Singular Value Decomposition, SVD)

奇异值分解与四个基本子空间

$$\mathbf{A}[\mathbf{v}_1 \cdots \mathbf{v}_r \cdots \mathbf{v}_n] = [\mathbf{u}_1 \cdots \mathbf{u}_r \cdots \mathbf{u}_m] \begin{bmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0 \end{bmatrix} \begin{cases} \mathbf{A}\mathbf{v}_i = \sigma_i \mathbf{u}_i, & 1 \leq i \leq r \\ \mathbf{A}\mathbf{v}_i = \mathbf{0}, & r+1 \leq i \leq n \end{cases}$$

- \mathbf{U} 的前 r 个列向量构成 $C(\mathbf{A})$ 的标准正交基
- \mathbf{V} 的后 $n-r$ 个列向量构成 $N(\mathbf{A})$ 的标准正交基

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \implies \mathbf{A}^T \mathbf{U} = \mathbf{V}\mathbf{\Sigma}^T \implies \begin{cases} \mathbf{A}^T \mathbf{u}_i = \sigma_i \mathbf{v}_i, & 1 \leq i \leq r \\ \mathbf{A}^T \mathbf{u}_i = \mathbf{0}, & r+1 \leq i \leq m \end{cases}$$

- \mathbf{V} 的前 r 个列向量构成 $C(\mathbf{A}^T)$ 的标准正交基
- \mathbf{U} 的后 $m-r$ 个列向量构成 $N(\mathbf{A}^T)$ 的标准正交基

奇异值分解的计算

$$\mathbf{A}_{m \times n} = \mathbf{U}_{m \times m} \mathbf{\Sigma}_{m \times n} \mathbf{V}_{n \times n}^T$$

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & -1 \end{bmatrix}$$

$$\mathbf{A}^T \mathbf{A} = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$$

$$\det(\mathbf{A}^T \mathbf{A} - \lambda \mathbf{I}) = (\lambda - 3)(\lambda - 1)$$

$$\sigma_1 = \sqrt{3}, \quad \sigma_2 = 1$$

\mathbf{v}_i 为 $\mathbf{A}^T \mathbf{A}$ 的标准正交特征向量

$\mathbf{A}^T \mathbf{A}$ 的属于特征值 3 和 1 的正交单位特征向量分别为：

$$(\mathbf{A}^T \mathbf{A} - 3\mathbf{I}) \mathbf{x} = \mathbf{0} \Rightarrow \mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} -1 \\ 1 \end{bmatrix} \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

奇异值分解的计算(续)

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} -1 \\ 1 \end{bmatrix} \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$


根据关系 $\mathbf{A}\mathbf{v}_i = \sigma_i \mathbf{u}_i$, $1 \leq i \leq r$, 可得:

$$\mathbf{u}_1 = \frac{1}{\sigma_1} \mathbf{A}\mathbf{v}_1 = \frac{1}{\sqrt{6}} \begin{bmatrix} -1 \\ 1 \\ -2 \end{bmatrix} \quad \mathbf{u}_2 = \frac{1}{\sigma_2} \mathbf{A}\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$$


根据正交性, 可得:

$$\begin{bmatrix} \mathbf{u}_1^T \\ \mathbf{u}_2^T \end{bmatrix} \mathbf{u}_3 = \mathbf{0} \xrightarrow{\text{red arrow}} \mathbf{u}_3 = \frac{1}{\sqrt{3}} \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix} \xrightarrow{\text{red arrow}} \mathbf{A} = [\mathbf{u}_1 \ \mathbf{u}_2 \ \mathbf{u}_3] \begin{bmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} [\mathbf{v}_1 \ \mathbf{v}_2]^T$$

奇异值分解的几何意义



奇异值分解的几何意义



(有些分量可能被置零)

奇异值分解的总结

$$\mathbf{A}_{m \times n} \mathbf{x} = \mathbf{U}_{m \times m} \mathbf{\Sigma}_{m \times n} \mathbf{V}_{n \times n}^T \mathbf{x}$$

$$\mathbf{x} = c_1 \mathbf{v}_1 + c_2 \mathbf{v}_2 + \cdots + c_n \mathbf{v}_n = [\mathbf{v}_1, \mathbf{v}_2, \cdots, \mathbf{v}_n] \begin{bmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{bmatrix} \Rightarrow \mathbf{c} = \mathbf{V}^T \mathbf{x}$$

1. 信号分解 (基底变换)

2. 响应求解 (能力受限)

$$\mathbf{\Sigma} \mathbf{c} = \begin{bmatrix} \sigma_1 & & & & \\ & \sigma_2 & & & \\ & & \ddots & & \\ & & & \sigma_r & \\ & & & & 0 \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{bmatrix} = \begin{bmatrix} \sigma_1 c_1 \\ \sigma_2 c_2 \\ \vdots \\ \sigma_r c_r \\ 0 \end{bmatrix}$$

$$\mathbf{U} \mathbf{\Sigma} \mathbf{c} = [\mathbf{u}_1, \mathbf{u}_2, \cdots, \mathbf{u}_m] \begin{bmatrix} \sigma_1 c_1 \\ \sigma_2 c_2 \\ \vdots \\ \sigma_r c_r \\ 0 \end{bmatrix} = \sigma_1 c_1 \mathbf{u}_1 + \sigma_2 c_2 \mathbf{u}_2 + \cdots + \sigma_r c_r \mathbf{u}_r$$

3. 基底变换

内容提要

- 奇异值分解的引入
 - 奇异值分解及其几何意义
 - 奇异值分解与图像数据压缩
 - 奇异值分解在多天线系统中的应用
-

奇异值分解与图像数据压缩

$$\mathbf{A}_{m \times n} = \mathbf{U}_{m \times m} \mathbf{\Sigma}_{m \times n} \mathbf{V}_{n \times n}^T$$
$$\mathbf{A} = \underbrace{\begin{bmatrix} \mathbf{u}_1 & \cdots & \mathbf{u}_r & \cdots & \mathbf{u}_m \end{bmatrix}}_{r \times m} \begin{bmatrix} \sigma_1 & & & & & \\ & \ddots & & & & \\ & & \sigma_r & & & \\ & & & & 0 & \\ 0 & & & & & 0 \end{bmatrix} \underbrace{\begin{bmatrix} \mathbf{v}_1^T \\ \vdots \\ \mathbf{v}_r^T \\ \vdots \\ \mathbf{v}_n^T \end{bmatrix}}_{r \times n}$$
$$= \underbrace{\sigma_1 \mathbf{u}_1 \mathbf{v}_1^T}_{\text{rank-1}} + \cdots + \underbrace{\sigma_r \mathbf{u}_r \mathbf{v}_r^T}_{\text{rank-1}} \quad r \text{ 个 rank-1 矩阵之和}$$

存储量下降:

压缩比:

$$m \times n \quad \Rightarrow \quad r \times (m + n + 1) \quad \frac{m \times n}{r \times (m + n + 1)}$$

奇异值分解与图像数据压缩


仅保留 k 个
最大奇异值
所对应的项

$$\mathbf{A} = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \cdots + \sigma_r \mathbf{u}_r \mathbf{v}_r^T$$

$$\mathbf{A}_k = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \cdots + \sigma_k \mathbf{u}_k \mathbf{v}_k^T$$



\mathbf{A}



\mathbf{A}_1



\mathbf{A}_5



\mathbf{A}_{20}



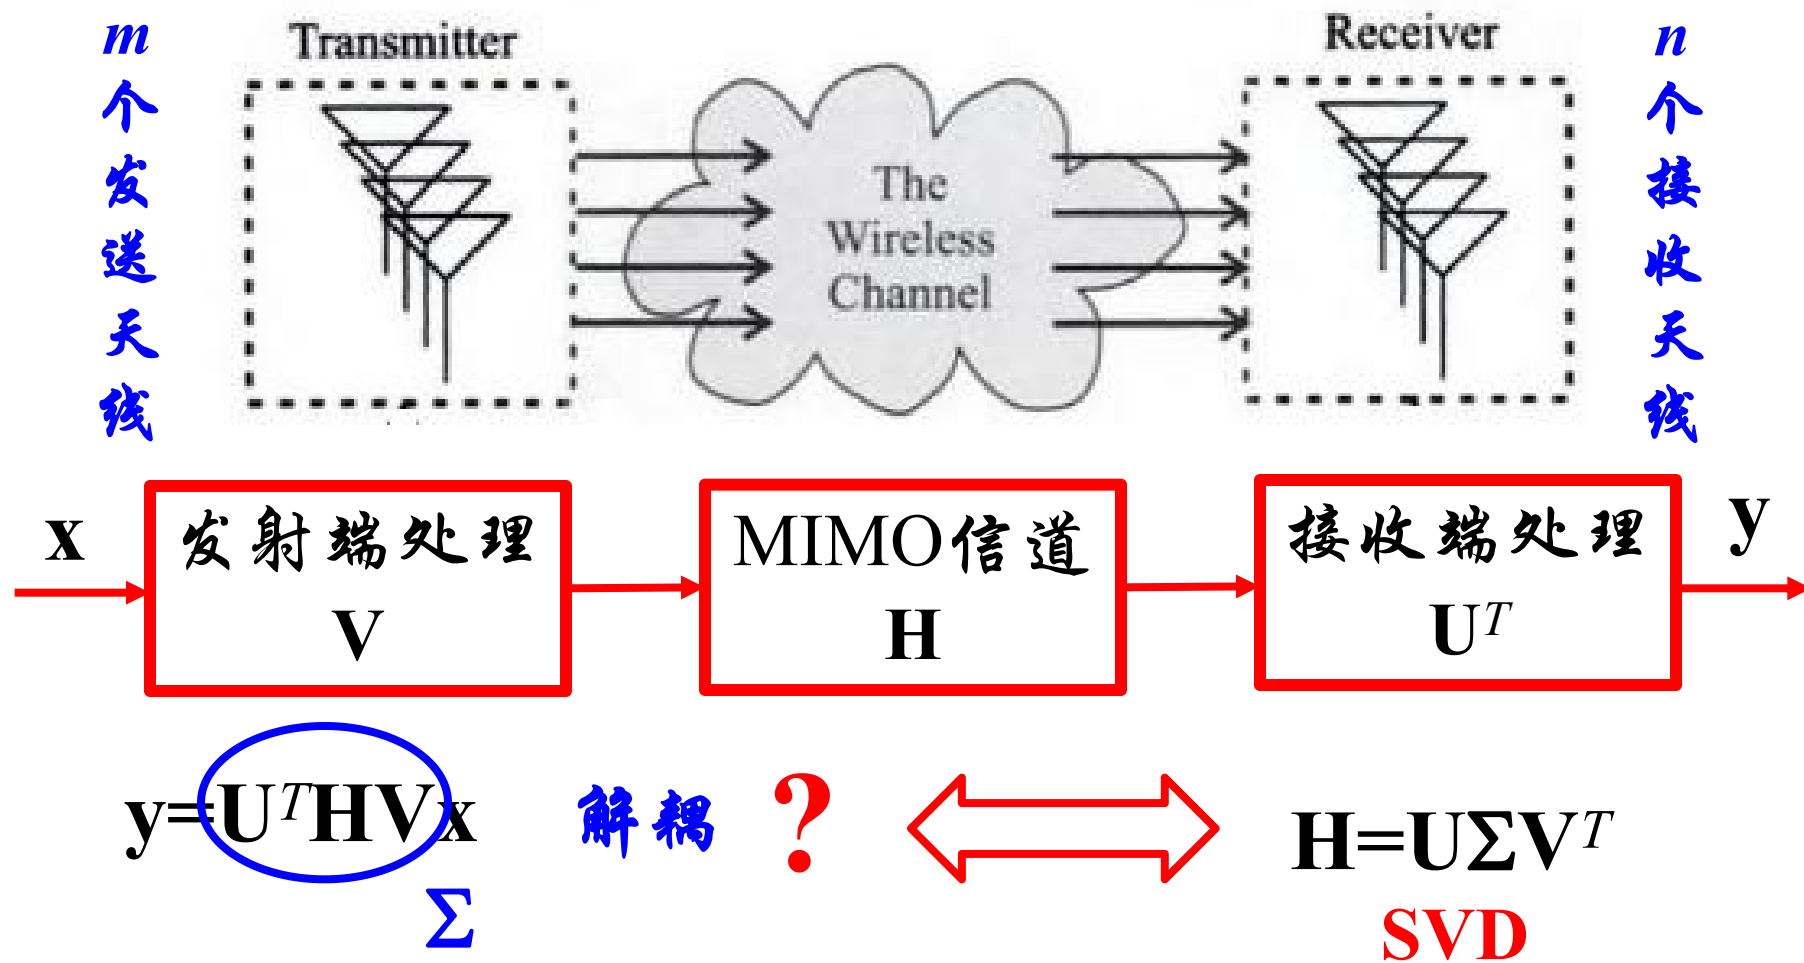
\mathbf{A}_{50}

$$450 \times 333 = 149850 \quad \Rightarrow \quad 50 \times (450 + 333 + 1) = 39200$$

内容提要

- 奇异值分解的引入
 - 奇异值分解及其几何意义
 - 奇异值分解与图像数据压缩
 - 奇异值分解在多天线系统中的应用
-


SVD与多天线通信系统



SVD与多天线通信系统

$$\mathbf{H}_{n \times m} = \mathbf{U}_{n \times n} \mathbf{\Sigma}_{n \times m} \mathbf{V}_{m \times m}^T$$


$$\mathbf{y}_{n \times 1} = \mathbf{U}_{n \times n}^T \mathbf{H}_{n \times m} \mathbf{V}_{m \times m} \mathbf{x}_{m \times 1}$$



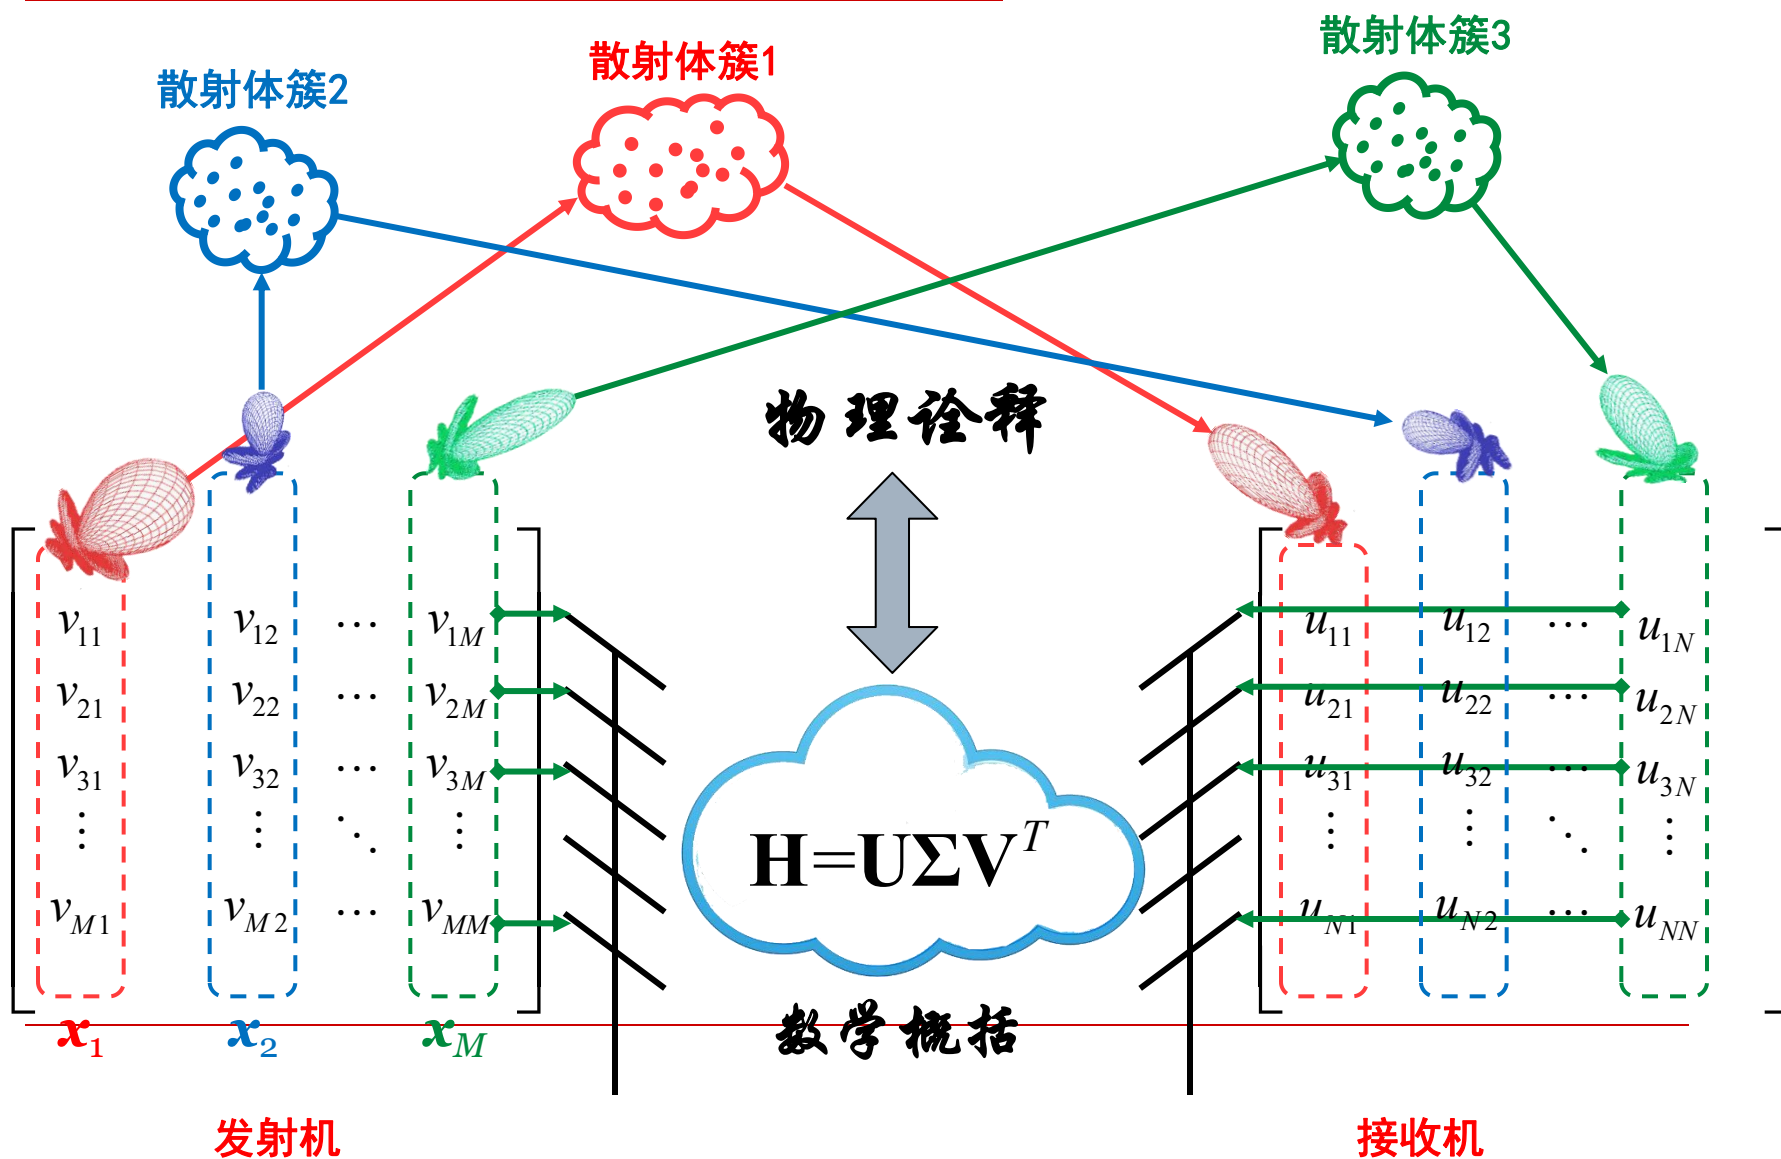
SVD与多天线通信系统

$$\mathbf{H}_{n \times m} = \mathbf{U}_{n \times n} \mathbf{\Sigma}_{n \times m} \mathbf{V}_{m \times m}^T$$

$$\mathbf{y}_{n \times 1} = \mathbf{U}_{n \times n}^T \mathbf{H}_{n \times m} \mathbf{V}_{m \times m} \mathbf{x}_{m \times 1}$$



SVD与多天线通信系统



谢谢大家！
