

总复习

贺丽君

信息与通信工程学院

Email: lijunhe@mail.xjtu.edu.cn

2023-04

内容提要

➤ 内容总结


➤ 典型例题

内容提要

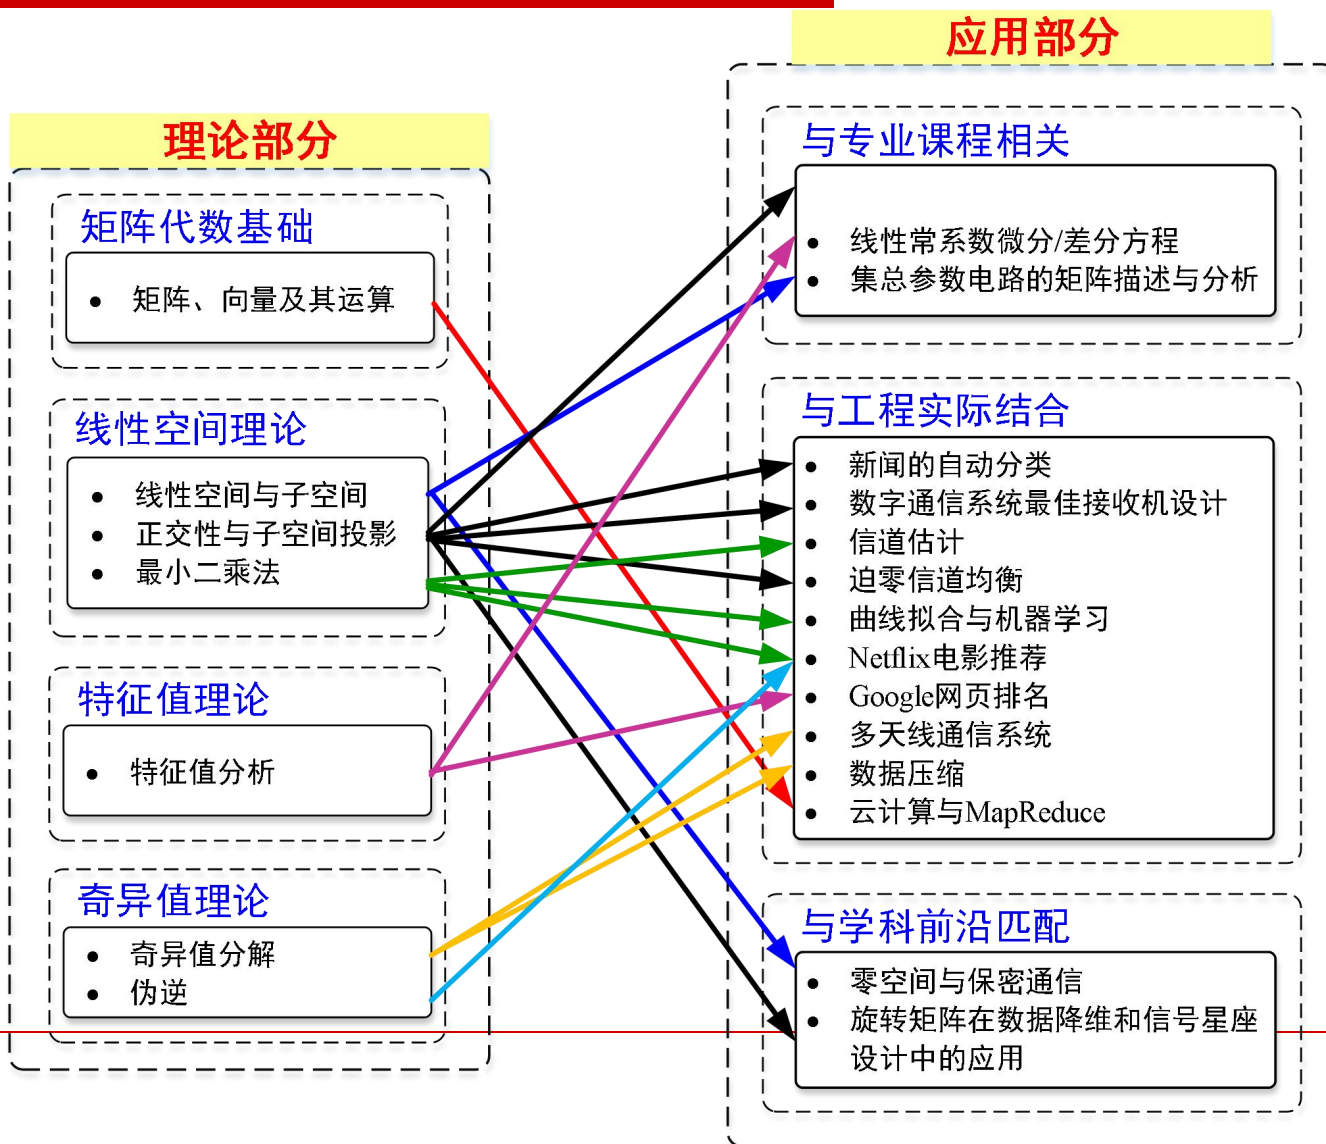
➤ 内容总结

➤ 典型例题

课程逻辑体系



课程内容体系



知识点小结

➤ 矩阵、向量及其运算

1. 矩阵乘法(含分块乘法)的内涵与计算

$$\mathbf{AB} = \mathbf{A} \begin{bmatrix} \mathbf{b}_1 & \cdots & \mathbf{b}_p \end{bmatrix} = \begin{bmatrix} \mathbf{Ab}_1 & \cdots & \mathbf{Ab}_p \end{bmatrix}$$

$$\mathbf{AB} = \begin{bmatrix} \mathbf{a}_1 \\ \vdots \\ \mathbf{a}_m \end{bmatrix} \mathbf{B} = \begin{bmatrix} \mathbf{a}_1 \mathbf{B} \\ \vdots \\ \mathbf{a}_m \mathbf{B} \end{bmatrix}$$

\mathbf{B} 的各行向量
的线性组合

\mathbf{A} 的各列向量
的线性组合

知识点小结

➤ 矩阵、向量及其运算

1. 矩阵乘法(含分块乘法)的内涵与计算

2. 消去矩阵与置换矩阵(性质)

□ 对 n 阶方阵, 共有 $n!$ 个置换矩阵

□ 如果 P 是置换矩阵, 则 P^T 也是置换矩阵

□ 若干个置换矩阵的乘积仍然是置换矩阵

□ 如果 P 是置换矩阵, 则 P^{-1} 也是置换矩阵

□ 对于置换矩阵 P , $P^T = P^{-1}$

知识点小结

➤ 矩阵、向量及其运算

1. 矩阵乘法(含分块乘法)的内涵与计算
2. 消去矩阵与置换矩阵(性质)
3. 逆矩阵与 Gauss-Jordan 方法(二阶方阵求逆)

构造增广矩阵

$$\left[\begin{array}{cc|cc} 1 & 3 & 1 & 0 \\ 2 & 7 & 0 & 1 \end{array} \right] \rightarrow \left[\begin{array}{cc|cc} 1 & 3 & 1 & 0 \\ 0 & 1 & -2 & 1 \end{array} \right] \rightarrow \left[\begin{array}{cc|cc} 1 & 0 & 7 & -3 \\ 0 & 1 & -2 & 1 \end{array} \right]$$

$\mathbf{A} \quad \mathbf{I} \qquad \qquad \qquad \mathbf{I} \quad \mathbf{A}^{-1}$

↓
 $\mathbf{E}[\mathbf{A} \quad \mathbf{I}]$

注意到

$$\mathbf{E}[\mathbf{A} \quad \mathbf{I}] = [\mathbf{EA} \quad \mathbf{EI}] = [\mathbf{I} \quad ?] \Rightarrow \mathbf{EA} = \mathbf{I}$$

$$\boxed{? = \mathbf{E} = \mathbf{A}^{-1}}$$

知识点小结

➤ 矩阵、向量及其运算

1. 矩阵乘法(含分块乘法)的内涵与计算
 2. 消去矩阵与置换矩阵(性质)
 3. 逆矩阵与 Gauss-Jordan 方法(二阶方阵求逆)
 4. 矩阵的 LU 分解
 5. 向量的内积与范数
-

知识点小结

➤ 矩阵、向量及其运算

下三角阵L: 对角线元素是1, 对角线下方是消元乘子

$$A = \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} \quad U = \begin{bmatrix} u_1 \\ u_2 \\ u_3 \end{bmatrix}$$

$$A = LU, EA = U \Rightarrow L = E^{-1}$$

$$\begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ l_{21} & 1 & 0 \\ l_{31} & l_{32} & 1 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \end{bmatrix}$$



$$u_1 = a_1 \Rightarrow a_1 = u_1$$

$$u_2 = a_2 - l_{21}a_1 \Rightarrow a_2 = l_{21}u_1 + u_2$$

$$u_3^{(1)} = a_3 - l_{31}a_1 \Rightarrow a_3 = u_3^{(1)} + l_{31}u_1$$

$$u_3^{(2)} = u_3^{(1)} - l_{32}u_2 \Rightarrow u_3^{(2)} = a_3 - l_{31}u_1 - l_{32}u_2$$

$$a_3 = l_{31}u_1 + l_{32}u_2 + u_3^{(2)}$$

知识点小结

➤ 线性空间与子空间

1. 线性空间、子空间的概念

- 设 V 是若干向量的集合， V 非空且对加法和数乘运算封闭，则集合 V 称为向量空间
 - 向量空间也称为线性空间
 - 任何向量空间必包含零向量
-

知识点小结

➤ 线性空间与子空间

1. 线性空间、子空间的概念
 2. 空间的基底与维数、子空间正交、正交补
 3. 矩阵的四个基本子空间及其相互关系
-

知识点小结

➤ 线性空间与子空间

➤ 列空间的定义

矩阵 A 的列空间 (记作 $C(A)$)由该矩阵各列的所有线性组合组成, 即所有可能的向量 Ax

➤ 列空间的基底与维数

□ A 的主列构成 $C(A)$ 的基底

□ 若 A 为 $m \times n$ 矩阵, 则 $C(A)$ 是 \mathbf{R}^m 的子空间, 且 $C(A)$ 的维数为 r

知识点小结

➤ 线性空间与子空间

➤ 零空间的定义

线性方程组 $Ax=0$ 的全部解构成矩阵 A 的零空间，用 $N(A)$ 表示。

➤ 零空间的基底与维数

- 齐次方程组 $Ax=0$ 的特解构成 $N(A)$ 的基底
 - 若 A 为 $m \times n$ 矩阵，则 $N(A)$ 是 \mathbf{R}^n 的子空间，其维数等于 $n-r$
-

知识点小结

➤ 线性空间与子空间

➤ 行空间的定义

矩阵 A 的行空间表示由 A 的各行向量所张成的子空间，用 $C(A^T)$ 表示。

➤ 几点说明

□ 矩阵 A 的行空间即为 A^T 的列空间

□ 若 A 为 $m \times n$ 矩阵，则 $C(A^T)$ 是 \mathbb{R}^n 的子空间

知识点小结

➤ 线性空间与子空间

➤ 左零空间的定义

矩阵 A 的左零空间定义为矩阵 A^T 的零空间，用 $N(A^T)$ 表示。

$$A^T y = 0 \quad \longleftrightarrow \quad y^T A = 0^T$$

□ 若 A 为 $m \times n$ 矩阵，则
 $N(A^T)$ 是 \mathbb{R}^m 的子空间

□ 左零空间的维数是 $m-r$



“左零”得名
的原因

知识点小结

➤ 线性空间与子空间

➤ 左零空间的基底

$$\mathbf{A} \xrightarrow{\mathbf{E}} \mathbf{R} = \begin{bmatrix} \mathbf{I} & \mathbf{F} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \quad \begin{array}{l} r \text{ 个主行, 线性无关} \\ m-r \text{ 个全零行} \end{array}$$


令

$$\mathbf{E} = \begin{bmatrix} \mathbf{u}_1^T \\ \mathbf{u}_2^T \\ \vdots \\ \mathbf{u}_m^T \end{bmatrix} \Rightarrow \mathbf{EA} = \begin{bmatrix} \mathbf{u}_1^T \mathbf{A} \\ \mathbf{u}_2^T \mathbf{A} \\ \vdots \\ \mathbf{u}_m^T \mathbf{A} \end{bmatrix} \Rightarrow \begin{array}{l} \mathbf{u}_k^T \mathbf{A} = \mathbf{0}^T, \\ k = r+1, \dots, m \end{array}$$

basis for $N(\mathbf{A}^T)$

\mathbf{A} 的左零空间的基底是初等行变换矩阵 \mathbf{E} 的最后 $m-r$ 行对应的向量

四个基本子空间的关系



1. 线性变换从 \mathbb{R}^n 映射到列空间； 2. 不是映射到 \mathbb{R}^m 空间； 3. 并非所有线性变化均可逆

知识点小结

➤ 线性空间与子空间

1. 线性空间、子空间的概念
 2. 空间的基底与维数、子空间正交、正交补
 3. 矩阵的四个基本子空间及其相互关系
 4. 线性方程组解的存在性与解的结构
 5. 矩阵的简化行阶梯形式
-

知识点小结

➤ 线性空间与子空间

例2 (续)

简化行阶梯形式(rref)

$$\mathbf{U} = \begin{bmatrix} 1 & 1 & 2 & 3 \\ 0 & 0 & 4 & 4 \\ 0 & 0 & 0 & 0 \end{bmatrix} \rightarrow \mathbf{R} = \begin{bmatrix} 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

简化行阶梯矩阵的特点:

□ 主元均为1, 主元上下均为零

□ 主行、主列相交处的元素构成单位阵

$$\mathbf{R} = \begin{bmatrix} \mathbf{I} & \mathbf{F} \\ \mathbf{0} & \mathbf{0} \end{bmatrix}$$

知识点小结

➤ 线性空间与子空间

$$\mathbf{R} = \begin{bmatrix} \textcircled{1} & \downarrow \text{F} & 1 & 0 & \downarrow \text{F} & 1 \\ 0 & 0 & \textcircled{1} & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

$$\mathbf{x} = c_1 \begin{bmatrix} -1 \\ 1 \\ 0 \\ 0 \end{bmatrix} + c_2 \begin{bmatrix} -1 \\ 0 \\ -1 \\ 1 \end{bmatrix}$$

$$\mathbf{Ax}=\mathbf{0} \iff \mathbf{Rx}=\mathbf{0} \quad \mathbf{R} = \begin{bmatrix} \mathbf{I} & \mathbf{F} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \implies \mathbf{N} = \begin{bmatrix} -\mathbf{F} \\ \mathbf{I} \end{bmatrix}$$

零空间矩阵，各
列由特解组成

知识点小结

➤ 线性空间与子空间

$Ax=b$ 解的结构

$$[A \ b] = \begin{bmatrix} 1 & 3 & 0 & 2 & 1 \\ 0 & 0 & 1 & 4 & 6 \\ 1 & 3 & 1 & 6 & 7 \end{bmatrix} \rightarrow \begin{bmatrix} 1 & 3 & 0 & 2 & 1 \\ 0 & 0 & 1 & 4 & 6 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix} = [R \ d]$$

P F P F

↓ ↓ ↓ ↓

➤ 第一步：求特解 x_p

□ 令自由变量 x_2, x_4 为零 $R \begin{bmatrix} x_{\text{pivot}} \\ x_{\text{free}} \end{bmatrix} = \begin{bmatrix} I & F \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x_{\text{pivot}} \\ x_{\text{free}} \end{bmatrix} = d$

主元变量 x_1, x_3 即
为 d 中非零元素

$$x_{\text{pivot}} = d' \quad \leftarrow \quad \begin{matrix} Ix_{\text{pivot}} + Fx_{\text{free}} = d' \\ x_{\text{free}} = 0 \end{matrix}$$

知识点小结

➤ 线性空间与子空间

$Ax=b$ 解的结构

$$[A \ b] = \begin{bmatrix} 1 & 3 & 0 & 2 & 1 \\ 0 & 0 & 1 & 4 & 6 \\ 1 & 3 & 1 & 6 & 7 \end{bmatrix} \longrightarrow \begin{array}{ccccc} & \begin{array}{c} \text{P} \\ \downarrow \end{array} & \begin{array}{c} \text{F} \\ \downarrow \end{array} & \begin{array}{c} \text{P} \\ \downarrow \end{array} & \begin{array}{c} \text{F} \\ \downarrow \end{array} \\ \begin{bmatrix} 1 & 3 & 0 & 2 & 1 \\ 0 & 0 & 1 & 4 & 6 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix} & \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} & \begin{bmatrix} 3 \\ 0 \\ 0 \end{bmatrix} & \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} & \begin{bmatrix} 2 \\ 4 \\ 0 \end{bmatrix} \end{array}$$

$= [R \ d]$

➤ 第二步：求齐次方程的解 x_n

$$Rx = 0 \longrightarrow N = \begin{bmatrix} -3 & -2 \\ 1 & 0 \\ 0 & -4 \\ 0 & 1 \end{bmatrix} \quad x = \begin{bmatrix} 1 \\ 0 \\ 6 \\ 0 \end{bmatrix} + c_1 \begin{bmatrix} -3 \\ 1 \\ 0 \\ 0 \end{bmatrix} + c_2 \begin{bmatrix} -2 \\ 0 \\ -4 \\ 1 \end{bmatrix}$$

$N = \begin{bmatrix} -F \\ I \end{bmatrix}$

完全解

知识点小结

➤ 线性空间与子空间

□ $r < m, r < n$, 简化行阶梯矩阵具有如下形式:

$$\mathbf{R} = \begin{bmatrix} \mathbf{I} & \mathbf{F} \\ \mathbf{0} & \mathbf{0} \end{bmatrix}$$

若要方程组有解, 则 \mathbf{d} 的最后 $m-r$ 个分量必为 0

□ $r < m, r < n$, 方程组 $\mathbf{Ax} = \mathbf{b}$ 没有解或有无穷多解

知识点小结

➤ 线性空间与子空间

- $r < m, r = n$: 列满秩的情况, 简化行阶梯矩阵具有如下形式:

$$\mathbf{R} = \begin{bmatrix} \mathbf{I} \\ \mathbf{0} \end{bmatrix}$$

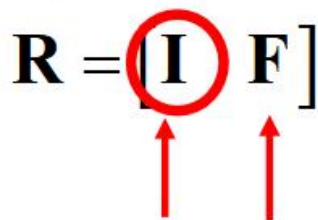
← $n \times n$ 单位阵
← $m-n$ 个全零行

- \mathbf{A} 的所有列都是主列, $N(\mathbf{A})$ 只包含零向量
 - 线性方程组 $\mathbf{Ax}=\mathbf{b}$ 无解或只有一个解
-

知识点小结

➤ 线性空间与子空间

- $r=m, r<n$: 行满秩的情况, 简化行阶梯矩阵具有如下形式:

$$R = [\mathbf{I} \quad \mathbf{F}]$$


m 个线性无关的列

$m \times m$ 单位阵 $n-m$ 个自由列 ($\mathbf{Ax}=\mathbf{0}$ 的特解)

- \mathbf{A} 的所有行都是主行, $C(\mathbf{A})=\mathbf{R}^m$.

- 对任意 \mathbf{b} , 线性方程组 $\mathbf{Ax}=\mathbf{b}$ 有无穷多解

知识点小结

➤ 线性空间与子空间

- $r=m=n$: A 为可逆方阵, 简化行阶梯矩阵具有如下形式:

$$R = [I]$$

- 对任意 b , 线性方程组 $Ax=b$ 有唯一解

$$x = A^{-1}b$$

知识点小结

➤ 正交性与子空间投影

1. 子空间投影的概念及计算
 2. 投影矩阵及其性质
-

向直线投影

正交性原理

$$\mathbf{a} \cdot (\mathbf{b} - \hat{x}\mathbf{a}) = 0$$




$$\hat{x} = \frac{\mathbf{a} \cdot \mathbf{b}}{\mathbf{a} \cdot \mathbf{a}} = \frac{\mathbf{a}^T \mathbf{b}}{\mathbf{a}^T \mathbf{a}}$$

$$\mathbf{p} = \frac{\mathbf{a}^T \mathbf{b}}{\mathbf{a}^T \mathbf{a}} \mathbf{a}$$

$$= \frac{\mathbf{a}\mathbf{a}^T}{\mathbf{a}^T \mathbf{a}} \mathbf{b}$$


投影矩阵 \mathbf{P}



问题：在 \mathbf{a} 上找一点，距离 \mathbf{b} 最近？


投影矩阵 (Projection Matrix)

$$\mathbf{P} = \frac{\mathbf{a}\mathbf{a}^T}{\mathbf{a}^T\mathbf{a}}$$



- \mathbf{P} 的列空间是通过 \mathbf{a} 的一条直线
- \mathbf{P} 由列向量乘以行向量得到，它的秩等于 1，称作秩 1 矩阵 (rank-1 matrix)
- \mathbf{P} 是对称矩阵，即： $\mathbf{P} = \mathbf{P}^T$
- \mathbf{P} 是等幂矩阵，即： $\mathbf{P}^2 = \mathbf{P}$
- $\mathbf{I} - \mathbf{P}$ 也是投影矩阵，将 \mathbf{b} 投影到与 \mathbf{a} 垂直的平面

子空间投影



假设各列
线性无关

$$\mathbf{A} = [\mathbf{a}_1 \cdots \mathbf{a}_n]$$

$$\begin{bmatrix} -\mathbf{a}_1^T \\ \vdots \\ -\mathbf{a}_n^T \end{bmatrix} \begin{bmatrix} \mathbf{b} - \mathbf{A}\hat{\mathbf{x}} \end{bmatrix} = \begin{bmatrix} 0 \end{bmatrix} \Rightarrow$$

\mathbf{A}^T

$$\hat{\mathbf{x}} = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{b}$$

$$\mathbf{p} = \mathbf{A}\hat{\mathbf{x}} = \mathbf{A}(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{b}$$

$$\mathbf{P} = \mathbf{A}(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T$$

$$\mathbf{P}^2 = \mathbf{P}, \mathbf{P}^T = \mathbf{P}$$

子空间投影

知识点小结

➤ 正交性与子空间投影

1. 子空间投影的概念及计算
 2. 投影矩阵及其性质
 3. 最小二乘法
-

最小二乘法的提出——直线拟合

$$\text{minimize } \|\mathbf{Ax} - \mathbf{b}\|^2$$

向量 \mathbf{b} 可以分解为两部分之和：

$$\mathbf{b} = \mathbf{p} + \mathbf{e}$$


列空间分量

左零空间分量

$$\|\mathbf{Ax} - \mathbf{b}\|^2 = \|\mathbf{Ax} - \mathbf{p} - \mathbf{e}\|^2 = \|\mathbf{Ax} - \mathbf{p}\|^2 + \|\mathbf{e}\|^2$$

该项等于零，则目标函数最小

$$\Rightarrow \hat{\mathbf{x}} = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{b} \quad (\text{最小二乘解, Least Squares})$$



知识点小结

➤ 正交性与子空间投影

1. 子空间投影的概念及计算
 2. 投影矩阵及其性质
 3. 最小二乘法
 4. 标准正交向量组、正交矩阵、特殊的正交矩阵
-

标准正交向量组

➤ 定义

- 当向量 $\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n$ 满足如下条件时，称这 n 个向量是标准正交的：

$$\mathbf{q}_i^T \mathbf{q}_j = \begin{cases} 0, & i \neq j \\ 1, & i = j \end{cases}$$

← 正交性
← 单位向量

- 若矩阵的各列由标准正交向量构成，则将该矩阵记作 \mathbf{Q} ，它满足如下性质：

$$\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$$

正交矩阵

➤ 定义

若矩阵 Q 的各列为标准正交向量且 Q 为方阵，则称 Q 为正交矩阵。正交矩阵满足如下性质：


□ Q 的各行向量也是标准正交的向量

$$Q^T Q = \textcircled{Q Q^T} = I$$

□ Q 的逆等于其转置

$$Q^T = Q^{-1}$$

正交矩阵与子空间投影



标准正交基

$$A = Q = [q_1 \cdots q_n]$$

解释了正交矩阵的性质

$$\hat{x} = Q^T b$$

$$p = Q\hat{x} = QQ^T b \xrightarrow{m=n} C(A) = \mathbb{R}^m \xrightarrow{\substack{\mathbf{b} \text{ 在列空间内} \\ P\mathbf{b} = \mathbf{b}}} QQ^T = \mathbf{I}$$

$$P = QQ^T$$

$$\hat{x} = Q^T b \iff x = Q^{-1} b$$


$$b = q_1 (q_1^T b) + q_2 (q_2^T b) + \cdots + q_n (q_n^T b)$$

正交基的分量之和

几个典型的正交矩阵

➤ 旋转

$$Q = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$



➤ 置换


$$\begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

➤ 反射

$$Q = I - 2uu^T$$

$$Qx = (I - uu^T - uu^T)x$$

$$= (I - uu^T)x - uu^T x$$



知识点小结

➤ 正交性与子空间投影

1. 子空间投影的概念及计算
 2. 投影矩阵及其性质
 3. 最小二乘法
 4. 标准正交向量组、正交矩阵、特殊的正交矩阵
 5. Gram-Schmidt 正变化与矩阵的QR分解
-

Gram-Schmidt 正变化

问题：如何由一组给定的向量 \mathbf{a}_1 、 \mathbf{a}_2 、 \mathbf{a}_3 ，构造一组标准正交向量 \mathbf{q}_1 、 \mathbf{q}_2 、 \mathbf{q}_3 ？

假定 \mathbf{a}_1 、 \mathbf{a}_2 、 \mathbf{a}_3 线性无关：

$$\mathbf{a}_1 \Rightarrow \mathbf{q}_1 = \mathbf{a}_1 / \|\mathbf{a}_1\|$$

$$\mathbf{a}_2 \Rightarrow \mathbf{B} = \mathbf{a}_2 - (\mathbf{q}_1^T \mathbf{a}_2) \mathbf{q}_1 \Rightarrow \mathbf{q}_2 = \mathbf{B} / \|\mathbf{B}\|$$

$$\mathbf{a}_3 \Rightarrow \mathbf{C} = \mathbf{a}_3 - (\mathbf{q}_1^T \mathbf{a}_3) \mathbf{q}_1 - (\mathbf{q}_2^T \mathbf{a}_3) \mathbf{q}_2$$

$$\mathbf{q}_3 = \mathbf{C} / \|\mathbf{C}\|$$

线性相关
的情况？

矩阵的QR分解

$$\begin{matrix} & & & \begin{matrix} \textcircled{\mathbf{q}_1^T \mathbf{a}_1} & \mathbf{q}_1^T \mathbf{a}_2 & \mathbf{q}_1^T \mathbf{a}_3 \\ & \textcircled{\mathbf{q}_2^T \mathbf{a}_2} & \mathbf{q}_2^T \mathbf{a}_3 \\ & & \textcircled{\mathbf{q}_3^T \mathbf{a}_3} \end{matrix} \\ \begin{bmatrix} \mathbf{a}_1 & \mathbf{a}_2 & \mathbf{a}_3 \end{bmatrix} = \begin{bmatrix} \mathbf{q}_1 & \mathbf{q}_2 & \mathbf{q}_3 \end{bmatrix} & \begin{matrix} \mathbf{R} \end{matrix} \\ \mathbf{A} & \mathbf{Q} \end{matrix}$$

- 任意列满秩矩阵 \mathbf{A} 都可以分解成一个列向量标准正交的矩阵 \mathbf{Q} 和一个上三角矩阵 \mathbf{R} 的乘积
 - 上三角矩阵 \mathbf{R} 的主对角线元素大于零，其数值等于正变化过程中产生的正交向量的范数
-

知识点小结

➤ 特征值分析

1. 特征值与特征向量、特殊矩阵的特征值

特征值与特征向量(Eigenvalue/vector)

➤ 定义

设 A 是一个 n 阶方阵，如果存在一个复数 λ 和一个非零向量 \mathbf{x} ，使得

$$A\mathbf{x} = \lambda\mathbf{x}$$

则称 λ 为矩阵 A 的特征值， \mathbf{x} 为 A 的对应于(或称属于) λ 的特征向量。

$$e^{st} \rightarrow y(t) = \left[\int_{-\infty}^{+\infty} h(\tau) e^{-s\tau} d\tau \right] e^{st}$$
$$e^{st} \rightarrow H(s) e^{st}$$

特征值与特征向量的物理含义？

特征值与特征向量的计算

➤ 特征值的计算

$$\mathbf{Ax} = \lambda \mathbf{x} \quad \longrightarrow \quad (\mathbf{A} - \lambda \mathbf{I}) \mathbf{x} = \mathbf{0}$$

特征方程

$$\det(\mathbf{A} - \lambda \mathbf{I}) = 0$$

特征多项式

解空间：特
征子空间

➤ 特征向量的计算

求解齐次线性方程组 $(\mathbf{A} - \lambda \mathbf{I}) \mathbf{x} = \mathbf{0}$ ，找出全部特解，即得对应于 λ 的线性无关的特征向量。

属于不同特征值的特征向量是线性无关的

关于特征值的几条性质

- 如果 A 是奇异矩阵, 则 $\lambda=0$ 是 A 的特征值
 - 如果 λ 是 A 的特征值, 则 λ^k 是 A^k 的特征值
 - 如果 λ 是可逆矩阵 A 的特征值, 则 λ 非零且 λ^{-1} 是 A^{-1} 的特征值
 - 三角矩阵的特征值等于其对角线元素, I 的特征值是1
 - 矩阵 A 的全部特征值之积等于矩阵 A 的行列式, 全部特征值之和等于矩阵 A 的对角线元素之和(A 的迹, trace)
 - 一般来说, $A+B$ 的特征值不等于 A 与 B 的特征值之和, AB 的特征值不等于 A 与 B 的特征值之积
-

几个特殊矩阵的特征值

➤ 投影矩阵

$$\mathbf{P} = \mathbf{A}(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T$$

$$\mathbf{P}\mathbf{x} = \lambda\mathbf{x}$$

$$\mathbf{x} \in C(\mathbf{A}), \mathbf{P}\mathbf{x} = \mathbf{x}, \lambda = 1$$

$$\mathbf{x} \perp C(\mathbf{A}), \mathbf{P}\mathbf{x} = \mathbf{0}, \lambda = 0$$

特征值: 1, 0

➤ 反射矩阵

$$\mathbf{Q} = \mathbf{I} - 2\mathbf{u}\mathbf{u}^T$$

$$\mathbf{x} \parallel \mathbf{u}, \mathbf{Q}\mathbf{x} = -\mathbf{x}, \lambda = -1$$

$$\mathbf{x} \perp \mathbf{u}, \mathbf{Q}\mathbf{x} = \mathbf{x}, \lambda = 1$$

特征值: -1, +1

➤ 90°旋转矩阵

$$\begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$$

特征值: $i, -i$

知识点小结

➤ 特征值分析

1. 特征值与特征向量、特殊矩阵的特征值
 2. 矩阵的对角化与特征分解
-

矩阵的对角化

充要条件：每个
特征值的代数重
数等于几何重数

➤ 矩阵对角化定理

假设 n 阶方阵 A 有 n 个线性无关的特征向量 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ ，将它们作为列向量构造特征向量矩阵 S ，则 $S^{-1}AS$ 是对角阵，且对角线元素等于 A 的特征值，将其称为特征值矩阵，即：

$$S^{-1}AS = \Lambda = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix}$$

知识点小结

➤ 特征值分析

1. 特征值与特征向量、特殊矩阵的特征值
 2. 矩阵的对角化与特征分解
 3. 矩阵指数函数集特征值分解在差分/微分方程中的应用(矩阵可以对角化的情况)
-

特征值分析与线性常系数微分方程

$$\frac{d\mathbf{u}}{dt} = \mathbf{A}\mathbf{u} \quad \longleftrightarrow \quad \begin{bmatrix} \frac{du_1}{dt} \\ \vdots \\ \frac{du_n}{dt} \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} u_1 \\ \vdots \\ u_n \end{bmatrix}$$

□ \mathbf{A} 可以对角化的情况

$$\mathbf{u}(t) = c_1 e^{\lambda_1 t} \mathbf{x}_1 + \cdots + c_n e^{\lambda_n t} \mathbf{x}_n$$

$$\frac{d\mathbf{u}}{dt} = \mathbf{A}\mathbf{u} = \mathbf{S}\mathbf{\Lambda}\mathbf{S}^{-1}\mathbf{u}$$

解耦

特征值决定
系统稳定性

$$\mathbf{u}(0) = c_1 \mathbf{x}_1 + \cdots + c_n \mathbf{x}_n$$

$$-\frac{d(\mathbf{S}^{-1}\mathbf{u})}{dt} = \mathbf{\Lambda}(\mathbf{S}^{-1}\mathbf{u}) \quad \longrightarrow \quad \mathbf{S}^{-1}\mathbf{u} = \begin{bmatrix} e^{\lambda_1 t} c_1 \\ \vdots \\ e^{\lambda_n t} c_n \end{bmatrix} \quad \longrightarrow \quad \mathbf{u} = \mathbf{S} \begin{bmatrix} e^{\lambda_1 t} c_1 \\ \vdots \\ e^{\lambda_n t} c_n \end{bmatrix}$$

知识点小结

➤ 特征值分析

1. 特征值与特征向量、特殊矩阵的特征值
 2. 矩阵的对角化与特征分解
 3. 在差分/微分方程中的应用(矩阵可以对角化的情况)
 4. Markov矩阵及其性质
-

Markov矩阵的性质

- 若 A 为 Markov 矩阵, 且 u_0 为一非负向量, 则 $u_1 = Au_0$ 为非负向量
- 若 A 为 Markov 矩阵且非负向量 u_0 的各元素之和等于 1, 则 $u_1 = Au_0$, $u_2 = A^2u_0$, ..., $u_k = A^k u_0$ 的各元素之和都等于 1
- 如果 A 是正的 Markov 矩阵 (各元素大于 0, 且每一列元素之和等于 1), 则 $\lambda = 1$ 是唯一的模为 1 的特征值, 其代数重数和几何重数均为 1, 与该特征值对应的特征向量各分量均大于 0; 其余所有特征值的模均小于 1

$A - I$ 各行向量相加为零 \Rightarrow 行向量线性相关

—— $\det(A - I) = 0 \Rightarrow (A - \lambda I) x = 0$ 在 $\lambda = 1$ 时, 有非零解 ——

正Markov矩阵

$$\begin{aligned}\mathbf{u}_k &= \mathbf{A}^k \mathbf{u}_0 \\ &= c_1 (\lambda_1)^k \mathbf{x}_1 + c_2 (\lambda_2)^k \mathbf{x}_2 + \dots + c_n (\lambda_n)^k \mathbf{x}_n\end{aligned}$$

假设上式中的各项满足：

$$|\lambda_1| \geq |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$$

如果 \mathbf{A} 是正Markov矩阵，则：

$$\mathbf{u}_k \rightarrow c_1 \mathbf{x}_1, \quad k \rightarrow \infty$$

最大特征值所对应的特征向量决定稳态，稳态与初值无关；第二大的特征值控制收敛速度


知识点小结

➤ 奇异值分解与伪逆

1. 奇异值分解的概念及计算

奇异值分解的引入

能否将行空间的正交基变换为列空间的正交基?



奇异值分解

$$\mathbf{A}\mathbf{v}_i = \sigma_i \mathbf{u}_i, \quad 1 \leq i \leq r$$

$$\mathbf{A}\mathbf{v}_i = \mathbf{0}, \quad r+1 \leq i \leq n$$

假设 $\mathbf{w}_1 \sim \mathbf{w}_n$ 是 n 维空间的任意一组标准正交基:

$$\{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_n\} \xrightarrow{\mathbf{A}} \{\mathbf{A}\mathbf{w}_1, \mathbf{A}\mathbf{w}_2, \dots, \mathbf{A}\mathbf{w}_n\}$$

如果要使各 $\mathbf{A}\mathbf{w}_i$ 两两正交, 应有:

$$(\mathbf{A}\mathbf{w}_i)^T \mathbf{A}\mathbf{w}_j = 0, \quad i \neq j$$

实对称
矩阵

即:

$$(\mathbf{w}_i)^T \mathbf{A}^T \mathbf{A} \mathbf{w}_j = 0, \quad i \neq j$$

1. 特征值全是实数 2. n 个标准正交的特征向量

奇异值分解

由于 $\mathbf{A}^T\mathbf{A}$ 是实对称矩阵，因此， $\mathbf{w}_1 \sim \mathbf{w}_n$ 可以选取为 $\mathbf{A}^T\mathbf{A}$ 的标准正交特征向量，此时有：

$$(\mathbf{w}_i)^T \mathbf{A}^T \mathbf{A} \mathbf{w}_j = (\mathbf{w}_i)^T \lambda_j \mathbf{w}_j = 0$$

而 $\mathbf{A}^T\mathbf{A}$ 的特征值具有如下两条性质：

□ $\mathbf{A}^T\mathbf{A}$ 和 $\mathbf{A}\mathbf{A}^T$ 的特征值均为非负实数

□ $\mathbf{A}^T\mathbf{A}$ 和 $\mathbf{A}\mathbf{A}^T$ 均有 r 个非零特征值，且非零特征值相同
所以有：

$$\mathbf{A}^T \mathbf{A} \mathbf{w}_i = \lambda_i \mathbf{w}_i, \quad 1 \leq i \leq r \quad (\lambda_i > 0)$$

$$\mathbf{A}^T \mathbf{A} \mathbf{w}_i = \mathbf{0}, \quad r+1 \leq i \leq n$$

$\mathbf{A}^T\mathbf{A}$ 实对称矩阵有 n 个特征值，其中 r 个非零， $n-r$ 个零

奇异值分解

$$(\mathbf{A}\mathbf{w}_i)^T \mathbf{A}\mathbf{w}_j = 0, \quad i \neq j$$

*orthogonal
basis for $C(\mathbf{A})$*

$$\mathbf{A}^T \mathbf{A}\mathbf{w}_i = \lambda_i \mathbf{w}_i, \quad 1 \leq i \leq r$$

$$\mathbf{A}^T \mathbf{A}\mathbf{w}_i = \mathbf{0}, \quad r+1 \leq i \leq n$$

零向量

注意到:

$$\|\mathbf{A}\mathbf{w}_i\|^2 = (\mathbf{A}\mathbf{w}_i)^T \mathbf{A}\mathbf{w}_i = \mathbf{w}_i^T \mathbf{A}^T \mathbf{A}\mathbf{w}_i = \mathbf{w}_i^T (\lambda_i \mathbf{w}_i) = \lambda_i$$

将列空间的正交基归一化可得标准正交基:

$$\mathbf{u}_i = \frac{\mathbf{A}\mathbf{w}_i}{\sqrt{\lambda_i}}, \quad 1 \leq i \leq r$$

奇异值分解

$$\mathbf{u}_i = \frac{\mathbf{A}\mathbf{w}_i}{\sqrt{\lambda_i}}, \quad 1 \leq i \leq r \quad \longleftrightarrow \quad \mathbf{A}\mathbf{w}_i = \sqrt{\lambda_i} \mathbf{u}_i, \quad 1 \leq i \leq r$$

又因为:

$$\mathbf{A}^T \mathbf{A} \mathbf{w}_i = \lambda_i \mathbf{w}_i, \quad 1 \leq i \leq r$$

所以:

$$\mathbf{A}^T \sqrt{\lambda_i} \mathbf{u}_i = \lambda_i \mathbf{w}_i, \quad 1 \leq i \leq r$$

$$\mathbf{A}^T \mathbf{u}_i = \sqrt{\lambda_i} \mathbf{w}_i, \quad 1 \leq i \leq r$$

行向量的线性组合

$\mathbf{w}_1, \dots, \mathbf{w}_r$ 是 $C(\mathbf{A}^T)$ 的标准正交基

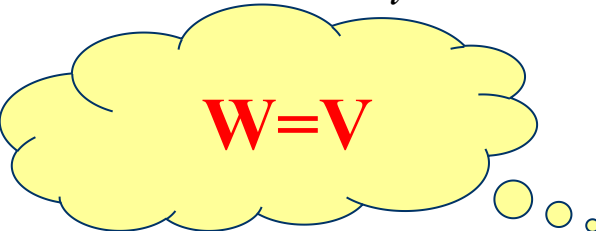
$$\mathbf{w}_i \in C(\mathbf{A}^T)$$

奇异值分解

另一方面：

$$\mathbf{A}^T \mathbf{A} \mathbf{w}_i = \mathbf{0}, \quad r+1 \leq i \leq n$$

$$\mathbf{w}_i^T \mathbf{A}^T \mathbf{A} \mathbf{w}_i = \|\mathbf{A} \mathbf{w}_i\|^2 = 0, \quad r+1 \leq i \leq n$$


$$\mathbf{W} = \mathbf{V}$$



$$\mathbf{A} \mathbf{w}_i = \mathbf{0}, \quad r+1 \leq i \leq n$$

$\mathbf{w}_{r+1}, \dots, \mathbf{w}_n$ 是 $N(\mathbf{A})$ 的标准正交基

$$\mathbf{A} \mathbf{w}_i = \sqrt{\lambda_i} \mathbf{u}_i, \quad 1 \leq i \leq r$$

$$\mathbf{A} \mathbf{w}_i = \mathbf{0}, \quad r+1 \leq i \leq n$$



$$\mathbf{A} \mathbf{v}_i = \sigma_i \mathbf{u}_i, \quad 1 \leq i \leq r$$

$$\mathbf{A} \mathbf{v}_i = \mathbf{0}, \quad r+1 \leq i \leq n$$

奇异值分解 (SVD)

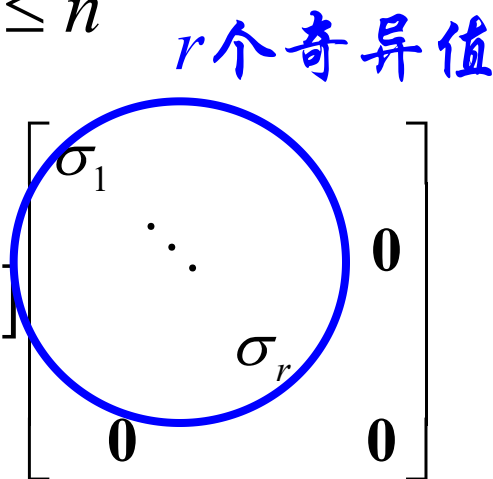
$$\mathbf{A}\mathbf{v}_i = \sigma_i \mathbf{u}_i, \quad 1 \leq i \leq r$$

$$\mathbf{A}\mathbf{v}_i = \mathbf{0}, \quad r+1 \leq i \leq n$$

右奇异向量 左奇异向量

$$\mathbf{A} \left[\underline{\mathbf{v}_1 \cdots \mathbf{v}_r} \cdots \mathbf{v}_n \right] = \left[\underline{\mathbf{u}_1 \cdots \mathbf{u}_r} \cdots \mathbf{u}_m \right]$$

r 个奇异值

$$\begin{bmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ \mathbf{0} & & & \mathbf{0} \end{bmatrix}$$


$$\mathbf{A}_{m \times n} = \mathbf{U}_{m \times m} \mathbf{\Sigma}_{m \times n} \mathbf{V}_{n \times n}^T$$

奇异值分解 (Singular Value Decomposition, SVD)

知识点小结

➤ 奇异值分解与伪逆

1. 奇异值分解的概念及计算
 2. 奇异值分解与四个基本子空间
-

奇异值分解与四个基本子空间

$$\mathbf{A}[\mathbf{v}_1 \cdots \mathbf{v}_r \cdots \mathbf{v}_n] = [\mathbf{u}_1 \cdots \mathbf{u}_r \cdots \mathbf{u}_m] \begin{bmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_r & \\ & & & 0 \end{bmatrix} \begin{cases} \mathbf{A}\mathbf{v}_i = \sigma_i \mathbf{u}_i, & 1 \leq i \leq r \\ \mathbf{A}\mathbf{v}_i = \mathbf{0}, & r+1 \leq i \leq n \end{cases}$$

- \mathbf{U} 的前 r 个列向量构成 $C(\mathbf{A})$ 的标准正交基
- \mathbf{V} 的后 $n-r$ 个列向量构成 $N(\mathbf{A})$ 的标准正交基

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \implies \mathbf{A}^T \mathbf{U} = \mathbf{V}\mathbf{\Sigma}^T \implies \begin{cases} \mathbf{A}^T \mathbf{u}_i = \sigma_i \mathbf{v}_i, & 1 \leq i \leq r \\ \mathbf{A}^T \mathbf{u}_i = \mathbf{0}, & r+1 \leq i \leq m \end{cases}$$


- \mathbf{V} 的前 r 个列向量构成 $C(\mathbf{A}^T)$ 的标准正交基
- \mathbf{U} 的后 $m-r$ 个列向量构成 $N(\mathbf{A}^T)$ 的标准正交基

知识点小结

➤ 奇异值分解与伪逆

1. 奇异值分解的概念及计算
 2. 奇异值分解与四个基本子空间
 3. 奇异值分解的几何意义
-

奇异值分解的几何意义




(有些分量可能被置零)

知识点小结

➤ 奇异值分解与伪逆

1. 奇异值分解的概念及计算
 2. 奇异值分解与四个基本子空间
 3. 奇异值分解的几何意义
 4. 伪逆的概念与计算
-

伪逆的提出



伪逆的定义

能够实现从列空间到行空间映射的线性变换

$$\mathbf{x}_r \in C(\mathbf{A}^T) \Rightarrow \mathbf{A}\mathbf{x}_r \in C(\mathbf{A})$$

把满足下列关系的矩阵 \mathbf{A}^+ 定义为 \mathbf{A} 的伪逆：

$$\mathbf{A}^+ (\mathbf{A}\mathbf{x}_r) = \mathbf{x}_r$$

注意到：

$$\mathbf{A}_{m \times n} = \mathbf{U}_{m \times m} \mathbf{\Sigma}_{m \times n} \mathbf{V}_{n \times n}^T$$

所以：

$$\mathbf{A}_{n \times m}^+ = \mathbf{V} \begin{bmatrix} \sigma_1^{-1} & & & 0 \\ & \ddots & & \\ & & \sigma_r^{-1} & \\ 0 & & & 0 \end{bmatrix} \mathbf{U}^T = \mathbf{V}_{n \times n} \mathbf{\Sigma}_{n \times m}^+ \mathbf{U}_{m \times m}^T$$

伪逆的定义

$$\mathbf{A}^+_{n \times m} = \mathbf{V} \begin{bmatrix} \sigma_1^{-1} & & & \mathbf{0} \\ & \ddots & & \\ & & \sigma_r^{-1} & \\ \mathbf{0} & & & \mathbf{0} \end{bmatrix} \mathbf{U}^T = \mathbf{V}_{n \times n} \mathbf{\Sigma}^+_{n \times m} \mathbf{U}_{m \times m}^T$$
$$\begin{aligned} \mathbf{A}^+ \mathbf{u}_i &= \sigma_i^{-1} \mathbf{v}_i, \quad 1 \leq i \leq r \\ \mathbf{A}^+ \mathbf{u}_i &= \mathbf{0}, \quad r+1 \leq i \leq m \end{aligned}$$

伪逆可以将列空间的正交基转化为行空间的正交基

伪逆可以将左零空间的向量映射为零向量

伪逆的性质

$$\mathbf{A}_{m \times n} \mathbf{A}_{n \times m}^+ = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T \mathbf{V} \mathbf{\Sigma}^+ \mathbf{U}^T = \mathbf{U} \mathbf{\Sigma} \mathbf{\Sigma}^+ \mathbf{U}^T = \mathbf{U} \begin{bmatrix} \mathbf{I}_r & 0 \\ 0 & 0 \end{bmatrix}_{m \times m} \mathbf{U}^T$$

1. $(\mathbf{A} \mathbf{A}^+)^T = \mathbf{A} \mathbf{A}^+$

2. $\mathbf{A} \mathbf{A}^+ = \mathbf{u}_1 \mathbf{u}_1^T + \cdots + \mathbf{u}_r \mathbf{u}_r^T$

3. $\mathbf{A} \mathbf{A}^+$ 是 \mathbf{R}^m 到 $C(\mathbf{A})$ 的投影矩阵

$\mathbf{b} \in \mathbf{R}^m \xrightarrow{\quad} \mathbf{b} = \mathbf{p} + \mathbf{e} \xrightarrow{\quad} \begin{aligned} \mathbf{A} \mathbf{A}^+ \mathbf{p} &= \mathbf{p} \\ \mathbf{A} \mathbf{A}^+ \mathbf{e} &= \mathbf{0} \end{aligned}$



伪逆的性质

$$\mathbf{A}^+ \mathbf{A} = \mathbf{V} \Sigma^+ \mathbf{U}^T \mathbf{U} \Sigma \mathbf{V}^T = \mathbf{V} \Sigma^+ \Sigma \mathbf{V}^T = \mathbf{V} \begin{bmatrix} \mathbf{I}_r & 0 \\ 0 & 0 \end{bmatrix}_{n \times n} \mathbf{V}^T$$

1. $(\mathbf{A}^+ \mathbf{A})^T = \mathbf{A}^+ \mathbf{A}$

2. $\mathbf{A}^+ \mathbf{A} = \mathbf{v}_1 \mathbf{v}_1^T + \cdots + \mathbf{v}_r \mathbf{v}_r^T$

3. $\mathbf{A}^+ \mathbf{A}$ 是 \mathbf{R}^n 到 $C(\mathbf{A}^T)$ 的投影矩阵

$$\mathbf{x} \in \mathbf{R}^n \quad \longrightarrow \quad \mathbf{x} = \mathbf{x}_r + \mathbf{x}_n \quad \longrightarrow \quad \begin{aligned} \mathbf{A}^+ \mathbf{A} \mathbf{x}_r &= \mathbf{x}_r \\ \mathbf{A}^+ \mathbf{A} \mathbf{x}_n &= \mathbf{0} \end{aligned}$$




知识点小结

➤ 奇异值分解与伪逆

1. 奇异值分解的概念及计算
 2. 奇异值分解与四个基本子空间
 3. 奇异值分解的几何意义
 4. 伪逆的概念与计算
 5. 伪逆与最小二乘法
-

伪逆与最小二乘解



考试安排

➤ 考试时间地点

5月14日，晚7:00-9:30

➤ 考试题型

五道大题，每题20分

➤ 考前答疑

时间：待定

地点：彭康楼132

内容提要

➤ 内容总结

➤ 典型例题

典型例题

已知 A 是 3×5 矩阵, 且 $Ax=b$ 对任意三维向量 b 均有解。

(1) 求 A 的列空间;

(2) 求 A 的零空间的维数;

(3) 设矩阵 $B = \begin{bmatrix} A \\ A \end{bmatrix}$, 求矩阵 B 的秩。

解 1:

$$(1). C(A) = \mathbb{R}^3$$

$$(2) r=3, \therefore n-r=5-3=2. \dim N(A)=2$$

$$(3) \begin{bmatrix} A \\ A \end{bmatrix} \rightarrow \begin{bmatrix} A \\ 0 \end{bmatrix} \quad \text{rank} = 3 (= \text{rank}(A))$$

典型例题

已知 4×4 矩阵 $A = \begin{bmatrix} I & 3I \\ 0 & 0 \end{bmatrix}$, 其中的分块均为 2×2 矩阵

- (1) 给出 A 的列空间的一个基底;
- (2) 给出 $C(A)$ 的所有可能基底应具有的形式;
- (3) 给出 A 的零空间的一个基底;
- (4) 求线性方程组 $Ax = [5 \ 4 \ 0 \ 0]^T$ 的通解。

解: (1) basis: $\begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$

典型例题

(2) A 的列空间中任一向量必有如下形式: $\begin{bmatrix} x \\ y \\ 0 \\ 0 \end{bmatrix}$, $\because \dim(CA) = 2$

$\therefore C(A)$ 的任一基底必有如下形式:

$$\vec{x}_1 = \begin{bmatrix} a \\ b \\ 0 \\ 0 \end{bmatrix}, \vec{x}_2 = \begin{bmatrix} c \\ d \\ 0 \\ 0 \end{bmatrix}, \text{ 由 } \vec{x}_1, \vec{x}_2 \text{ 线性无关得: } \begin{bmatrix} a \\ b \end{bmatrix} \text{ 与 } \begin{bmatrix} c \\ d \end{bmatrix} \text{ 无关.}$$

$$\therefore \begin{bmatrix} a & c \\ b & d \end{bmatrix} \text{ 为满秩矩阵, 即: } \det \left(\begin{bmatrix} a & c \\ b & d \end{bmatrix} \right) = ad - bc \neq 0$$

$\therefore C(A)$ 所有子集的基底为满秩的形式为: $\begin{bmatrix} a \\ b \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} c \\ d \\ 0 \\ 0 \end{bmatrix}$, 满足 $ad - bc \neq 0$.

典型例题

$$(3) \quad A = \left[\begin{array}{c|c} I & \begin{bmatrix} 3 & 1 \end{bmatrix} \\ \hline 0 & 0 \end{array} \right]^F \quad \therefore \text{basis: } \begin{bmatrix} -3 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ -3 \\ 1 \end{bmatrix}$$

$$(4) \quad \text{因为 } A \text{ 已化为行阶梯形式 } R, \text{ 所以特解 } \vec{x}_p = \begin{bmatrix} 5 \\ 4 \\ 0 \\ 0 \end{bmatrix}$$
$$\text{通解为: } \vec{x} = \begin{bmatrix} 5 \\ 4 \\ 0 \\ 0 \end{bmatrix} + C_1 \begin{bmatrix} -3 \\ 0 \\ 1 \\ 0 \end{bmatrix} + C_2 \begin{bmatrix} 0 \\ 0 \\ -3 \\ 1 \end{bmatrix}.$$

典型例题

$$\mathbf{B} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & -1 & 2 \\ 0 & 1 & 1 & -1 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

(1) 给出 \mathbf{B} 的零空间的一个基底;

(2) 求线性方程组 $\mathbf{B}\mathbf{x} = [1 \ 0 \ 1]^T$ 的通解。

典型例题

例3:

(1) $B = C \cdot D$, 证明 C 是满秩矩阵, D 是简化行阶梯形式 $\begin{bmatrix} I & F \\ 0 & 0 \end{bmatrix}$

$$\therefore N(CD) = N(D)$$

证法一: 假设 $\vec{x} \in N(D)$, 则 $D\vec{x} = \vec{0} \Rightarrow CD\vec{x} = \vec{0} \Rightarrow \vec{x} \in N(CD)$

另一方面, 若 $\vec{x} \in N(CD)$, 则 $CD\vec{x} = \vec{0} \Rightarrow C^{-1}CD\vec{x} = \vec{0} \Rightarrow D\vec{x} = \vec{0} \Rightarrow \vec{x} \in N(D)$

从而说明 $N(D) = N(CD)$

对于 D 矩阵, 它有 rref 形式, $\therefore \dim(N(D)) = 2$. basis for $N(D)$: $\begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}, \begin{bmatrix} -2 \\ 1 \\ 1 \end{bmatrix}$

$\therefore B$ 的零空间的一个基底是 $\begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}, \begin{bmatrix} -2 \\ 1 \\ 1 \end{bmatrix}$

典型例题

(2) 令 D 的各列向量分别为 $\vec{d}_1, \vec{d}_2, \vec{d}_3, \vec{d}_4$,

$$\text{令 } B = CD = [C\vec{d}_1 \ C\vec{d}_2 \ C\vec{d}_3 \ C\vec{d}_4]$$

其中 $C\vec{d}_1 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$ (B 的第一列)。令 $B\vec{x} = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$ (B 的第一列), 则取 $\vec{x} = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$

$\therefore B\vec{x} = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$ 的一个特解为: $\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$, 通解为: $\vec{x} = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} + C_1 \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} + C_2 \begin{bmatrix} -2 \\ 1 \\ 1 \end{bmatrix}$

典型例题

$$\mathbf{b} = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 1 \end{bmatrix}, \mathbf{a}_1 = \begin{bmatrix} 1 \\ 7 \\ 1 \\ 7 \end{bmatrix}, \mathbf{a}_2 = \begin{bmatrix} -1 \\ 7 \\ 1 \\ -7 \end{bmatrix}$$

- (1) 将向量 \mathbf{b} 投影到由 \mathbf{a}_1 和 \mathbf{a}_2 所张成的子空间，求投影向量 \mathbf{p} ；
 - (2) 求实现上述投影的投影矩阵 \mathbf{P} ；
 - (3) 求 \mathbf{P} 的与特征值1对应的所有特征向量。
-

典型例题

例4:

$$(1) \because \vec{a}_1 \text{ 和 } \vec{a}_2 \text{ 是 } \vec{\alpha}_1, \\ \therefore \vec{p} = \frac{\vec{a}_1^T \vec{b}}{\vec{a}_1^T \vec{a}_1} \vec{a}_1 + \frac{\vec{a}_2^T \vec{b}}{\vec{a}_2^T \vec{a}_2} \vec{a}_2 = \begin{bmatrix} 4/25 \\ 0 \\ 0 \\ 28/25 \end{bmatrix}$$

$$(2) P = A(A^T A)^{-1} A^T$$

$$A^T A = \begin{bmatrix} 100 & 0 \\ 0 & 100 \end{bmatrix}$$

$$(1) \text{ 这里利用 } \vec{\alpha}_2 \text{ 与 } \vec{\alpha}_1 \text{ 正交}. \therefore P = \frac{1}{100} A A^T = \frac{1}{100} \begin{bmatrix} 2 & 0 & 0 & 14 \\ 0 & 98 & 14 & 0 \\ 0 & 14 & 2 & 0 \\ 14 & 0 & 0 & 98 \end{bmatrix}$$

与1所对应的特征向量满足: $P\vec{x} = \vec{x}$, $\therefore \vec{x} \in C(A)$. 即: $\vec{x} = c_1 \vec{a}_1 + c_2 \vec{a}_2$.

典型例题

$$\mathbf{A} = \begin{bmatrix} 3 & 6 & 6 \\ 4 & 8 & 8 \end{bmatrix}$$

- (1) 求出将任一向量投影到矩阵 \mathbf{A} 的列空间的投影矩阵 \mathbf{P}_C ;
 - (2) 求出将任一向量投影到矩阵 \mathbf{A} 的行空间的投影矩阵 \mathbf{P}_R ;
 - (3) 计算 $\mathbf{B} = \mathbf{P}_C \mathbf{A} \mathbf{P}_R$, 并解释所得到的结果。
-

典型例题

(1) $C(A)$: $\dim=1$, basis: $\begin{bmatrix} 3 \\ 4 \end{bmatrix} \triangleq \vec{a}$. $\rightarrow A$ 在 $\{\vec{a}\}$ 上的投影即为向 \vec{a} 投影.

$$\therefore P_C = \frac{\vec{a}\vec{a}^T}{\vec{a}^T\vec{a}} = \frac{1}{25} \begin{bmatrix} 3 \\ 4 \end{bmatrix} \begin{bmatrix} 3 & 4 \end{bmatrix} = \frac{1}{25} \begin{bmatrix} 9 & 12 \\ 12 & 16 \end{bmatrix}$$

(2). $C(A^T)$: $\dim=1$, basis: $\begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}$

$$\therefore P_R = \frac{1}{9} \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix} \begin{bmatrix} 1 & 2 & 2 \end{bmatrix} = \frac{1}{9} \begin{bmatrix} 1 & 2 & 2 \\ 2 & 4 & 4 \\ 2 & 4 & 4 \end{bmatrix}$$

典型例题

$$P_C A = P_C [\vec{a}_1 \ \vec{a}_2 \ \vec{a}_3] = [P_C \vec{a}_1 \ P_C \vec{a}_2 \ P_C \vec{a}_3]$$

$\because \vec{a}_1, \vec{a}_2, \vec{a}_3 \in C(A)$, 而 P_C 表示向 $C(A)$ 投影的投影矩阵

$$\therefore P_C A = [\vec{a}_1 \ \vec{a}_2 \ \vec{a}_3] = A.$$

$$\text{同理: } P_R^T A^T = P_R A^T = P_R [\vec{col}_1 \ \vec{col}_2] = [P_R \vec{col}_1 \ P_R \vec{col}_2] = [\vec{col}_1 \ \vec{col}_2] = A^T.$$

(\because 投影矩阵是对称的) \uparrow \uparrow
 A 的第 1 列 A 的第 2 列

$$\text{即: } P_R^T A^T = A^T$$

$$\therefore A P_R = A.$$

$$\text{故 } B = P_C A P_R = A P_R = A.$$

典型例题

$$\mathbf{A} \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} \hat{c} \\ \hat{d} \end{bmatrix} = \begin{bmatrix} 3 \\ 4 \\ 1 \end{bmatrix} \mathbf{b} \quad \begin{bmatrix} \hat{c} \\ \hat{d} \end{bmatrix} = \begin{bmatrix} \frac{11}{3} \\ -1 \end{bmatrix}$$

(1) 求出将向量 \mathbf{b} 投影到 \mathbf{A} 的列空间的投影矩阵 \mathbf{P} ;

$$(1) \quad \mathbf{P} = \mathbf{A}(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T$$


(2) 画出由上述最小二乘法所拟合出的直线;

(3) 找到另外一个右侧向量 \mathbf{b} , 使得

$$\begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} \hat{c} \\ \hat{d} \end{bmatrix} = \mathbf{b} \quad \begin{bmatrix} \hat{c} \\ \hat{d} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

典型例题

$$(2) \quad y = \hat{C} + \hat{D}t \\ = -t + \frac{11}{3}$$



(3) $A\vec{x} = \vec{b}$ 有 LS 解 即 $A\vec{x} = \vec{p}$ 有解.

最小二乘解为 $\begin{bmatrix} 0 \\ 0 \end{bmatrix} \Rightarrow \vec{p} = \vec{0}$, 即 \vec{b} 向 A 的列空间投影得到 \vec{p} 是零向量,

$$\Rightarrow \vec{b} \perp C(A) \Leftrightarrow \vec{b} \in N(A^T).$$

取 $\vec{b} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ (满足): $\begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix} \vec{b} = \vec{0} \Rightarrow \vec{b} = c \begin{bmatrix} 1 \\ -2 \\ 1 \end{bmatrix}$ c 为任意常数

A^T

典型例题

$$\mathbf{A} = \begin{bmatrix} 0.2 & 0.4 & 0.3 \\ 0.4 & 0.2 & 0.3 \\ 0.4 & 0.4 & 0.4 \end{bmatrix}$$

(1) 求矩阵 \mathbf{A} 的特征值;

(2) 已知 $\mathbf{u}_0 = [0 \ 10 \ 0]^T$, 且 $\mathbf{u}_k = \mathbf{A}^k \mathbf{u}_0$, 则当 $k \rightarrow \infty$ 时, $\mathbf{u}_k \rightarrow ?$

典型例题

(1) $\because A$ 是 Markov 矩阵, $\therefore \lambda_1 = 1$

$\because A$ 是奇异矩阵 ($\text{col } 1 + \text{col } 2 = 2\text{col } 3$) $\therefore \lambda_2 = 0$

又 $\because \lambda_1 + \lambda_2 + \lambda_3 = \text{tr}(A) = 0.2 + 0.2 + 0.4 = 0.8, \therefore \lambda_3 = -0.2$

(2) $\because A$ 有 3 个相异的特征值, $\therefore A$ 可以对角化.

$$A^k \vec{u}_0 = C_1 \lambda_1^k \vec{x}_1 + C_2 \lambda_2^k \vec{x}_2 + C_3 \lambda_3^k \vec{x}_3$$

当 $k \rightarrow \infty$ 时, $\vec{u}_k \rightarrow C_1 \vec{x}_1$

容易求得: 与 $\lambda_1 = 1$ 对应的特征向量为 $\vec{x}_1 = \begin{bmatrix} 3 \\ 3 \\ 4 \end{bmatrix}$

典型例题

又：在转移过程中 \vec{u}_k 的各分量之和保持不变，

$$\begin{aligned}[1, 1, \dots] \mathbf{A} &= [1, 1, \dots] \Rightarrow [1, 1, \dots] \mathbf{A} \mathbf{u}_0 = [1, 1, \dots] \mathbf{u}_0 = 1 \\ [1, 1, \dots] \mathbf{u}_1 &= 1\end{aligned}$$

$$\therefore 0 + 10 + 6 = 9(3 + 3 + 4) \Rightarrow 9 = 1$$

$$\text{故: } \vec{u}_k \rightarrow \begin{bmatrix} 3 \\ 3 \\ 4 \end{bmatrix} \quad (k \rightarrow \infty)$$

典型例题

假设 A 是一个 2×2 的实对称矩阵，它具有两个单位特征向量 u_1 和 u_2 。如果该矩阵的特征值为 $\lambda_1=3$ ， $\lambda_2=-2$ ，求矩阵 A 的奇异值分解。

$$A = U \Sigma V^T \quad \text{记: } U = [\tilde{u}_1 \ \tilde{u}_2], \ V = [\vec{v}_1 \ \vec{v}_2]$$

$2 \times 2 \quad 2 \times 2 \quad 2 \times 2 \quad 2 \times 2$

$\because A$ 为实对称矩阵, $\therefore A^T = A$, 又 $A^T A = A^2$, 它的特征值为 $\lambda_1^2 = 3^2 = 9$, $\lambda_2^2 = (-2)^2 = 4$.

$$\therefore A \text{ 的奇异值为: } \sigma_1 = 3, \sigma_2 = 2. \Rightarrow \Sigma = \begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix}$$

易证: $A^T A$ 的特征向量与 A 的特征向量相同,

$$(\text{设 } A\vec{x} = \lambda\vec{x}, \text{ 则 } \underline{A^T A \vec{x}} = \lambda A^T \vec{x} = \lambda A \vec{x} = \underline{\lambda^2 \vec{x}})$$

典型例题

取: \vec{u}_1, \vec{u}_2 是 $A^T A$ 的正交特征向量

又: A 是实对称矩阵, \therefore 相属于不同特征值的特征向量 \vec{u}_1 和 \vec{u}_2 正交. $\Rightarrow V = [\vec{u}_1 \ \vec{u}_2]$

$$\text{根据 } A\vec{u}_1 = \sigma_1 \tilde{\vec{u}}_1 \Rightarrow \tilde{\vec{u}}_1 = \frac{A\vec{u}_1}{\sigma_1} = \frac{A\vec{u}_1}{\sigma_1} = \frac{\lambda_1 \vec{u}_1}{\sigma_1} = \frac{3\vec{u}_1}{3} = \vec{u}_1.$$

$$\text{同理: } \tilde{\vec{u}}_2 = -\vec{u}_2$$

$$\therefore U = [\vec{u}_1 \ -\vec{u}_2], \Rightarrow A = [\vec{u}_1 \ -\vec{u}_2] \begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix} [\vec{u}_1 \ \vec{u}_2]^T.$$

典型例题

7、对于一个 3 阶方阵 \mathbf{A} ，已知它的三个特征值是 $\lambda_1 = 0$ ， $\lambda_2 = c$ ， $\lambda_3 = 2$ ，且该矩阵有 3 个特征向量：

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}, \quad \mathbf{x}_3 = \begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix}$$

- (1) 当 c 满足什么条件时， \mathbf{A} 可以对角化？
 - (2) 当 c 满足什么条件时， \mathbf{A} 是 Markov 矩阵？
 - (3) 当 c 满足什么条件时， $\frac{\mathbf{A}}{2}$ 是投影矩阵？
-

典型例题

7. (1) $\because \vec{x}_1, \vec{x}_2, \vec{x}_3$ 相互正交 (线性无关)

$\therefore c$ 取任何值时, A 都可以对角化

(2) $\lambda_3 = 2 > 1$. $\therefore c$ 取任何值, A 都不是 Markov 矩阵

(3) 投影矩阵的特征值为 $\lambda_1 = 1, \lambda_2 = 0$

$\therefore \frac{A}{2}$ 有特征值 1, 0

而 $\frac{A}{2}$ 的特征值为 $0, \frac{c}{2}, 1$. $\Rightarrow c = 0$ 或 2

典型例题

9、求如下三个矩阵的零空间矩阵 N :

$$A = [I \quad I], \quad B = \begin{bmatrix} I & I \\ 0 & 0 \end{bmatrix}, \quad C = [I \quad I \quad I]$$

不失一般性, 假设^I为 n 阶单位阵

$$A = [I \quad I] \triangleq [I \quad F], \quad \therefore N = \begin{bmatrix} -I \\ I \end{bmatrix} \quad (2n \times n)$$

$$B = \begin{bmatrix} I & I \\ 0 & 0 \end{bmatrix}, \quad \therefore N = \begin{bmatrix} -I \\ I \end{bmatrix} \quad (2n \times n)$$

$$C = [I \quad \underbrace{I \quad I}_F] \triangleq [I \quad F] \quad \therefore N = \begin{bmatrix} -(I \quad I) \\ I_{2n \times 2n} \end{bmatrix} \quad (3n \times 2n)$$

典型例题

10、方程组 $\mathbf{Ax} = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$ 的完全解是 $\mathbf{x} = \begin{bmatrix} 1 \\ 0 \end{bmatrix} + c \begin{bmatrix} 0 \\ 1 \end{bmatrix}$ ，求 \mathbf{A} 。

10. 由题可知: $A \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$, $\therefore A = \begin{bmatrix} 1 & * \\ 3 & * \end{bmatrix}$

$A \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ $\therefore A$ 的第二列为 $\begin{bmatrix} 0 \\ 0 \end{bmatrix}$, $\Rightarrow A = \begin{bmatrix} 1 & 0 \\ 3 & 0 \end{bmatrix}$

典型例题

5、已知矩阵 $\mathbf{A} = \begin{bmatrix} a & 1 \\ 1 & a \end{bmatrix}$, $\mathbf{B} = \begin{bmatrix} b & -1 \\ 1 & b \end{bmatrix}$, 其中 a 和 b 均为实数。求出 a 和 b 应满足

的条件, 使得 $\frac{d\mathbf{u}}{dt} = \mathbf{A}\mathbf{u}$ 和 $\frac{d\mathbf{v}}{dt} = \mathbf{B}\mathbf{v}$ 的解在 $t \rightarrow \infty$ 时收敛至 $\mathbf{0}$ 。

$$\det(\mathbf{A} - \lambda \mathbf{I}) = (a - \lambda)^2 - 1 = 0 \Rightarrow \lambda_1 = a - 1, \lambda_2 = a + 1$$

$\therefore \mathbf{A}$ 是可对角化 (= 矩阵有两个相异的特征值)

$$\text{故 } \frac{d\vec{u}}{dt} = \mathbf{A}\vec{u} \text{ 的解为 } c_1 e^{\lambda_1 t} \vec{x}_1 + c_2 e^{\lambda_2 t} \vec{x}_2 \triangleq \vec{u}(t)$$

$$\text{若 } t \rightarrow \infty \text{ 时, } \vec{u}(t) \rightarrow \vec{0} \Rightarrow \left. \begin{array}{l} a - 1 < 0 \\ a + 1 < 0 \end{array} \right\} \Rightarrow a < -1$$

典型例题

同理: $\det(B - \lambda I) = 0 \Rightarrow \lambda_1 = b - i, \lambda_2 = b + i$

$\frac{d\vec{v}}{dt} = B\vec{v}$ 的通解 $\vec{v}(t) = d_1 e^{\lambda_1 t} \vec{y}_1 + d_2 e^{\lambda_2 t} \vec{y}_2$

$\vec{v}(t) \rightarrow \vec{0} \quad (t \rightarrow \infty) \Leftrightarrow \operatorname{Re}\{\lambda_i\} < 0 \Rightarrow b < 0.$

感谢选修本课程！
祝大家考试顺利！
